



UNIVERSITAS INDONESIA

Fakultas Teknik – Departemen Teknik Mesin

PREDIKSI *REMAINING USEFUL LIFE*
MESIN TURBOFAN MENGGUNAKAN
ARTIFICIAL NEURAL NETWORK
PADA DATASET C-MAPSS

Mata Kuliah:

Data Analitik

Dosen Pengampu:

Dr. Eng. Sholahudin, S.T., M.Sc.

Disusun Oleh:

2506565466 Luqman Alifio Arhab
2506565414 Azfa Rhazasta Abiandra
2506565401 Adamsyah Haryo Saksono
2506565433 Epsiarto Rizqi Nurwijayadi

DEPARTEMEN TEKNIK MESIN
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

2026

1 Pendahuluan

Prediksi *Remaining Useful Life* (RUL) merupakan komponen penting dalam *prognostics and health management* (PHM) sistem mekanik. Dengan mengetahui sisa umur pakai suatu komponen, jadwal perawatan dapat dioptimalkan sehingga mengurangi biaya *downtime* dan risiko kegagalan mendadak.

Laporan ini mendokumentasikan pipeline analitik lengkap untuk memprediksi RUL mesin turbofan menggunakan dataset C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) dari NASA [1]. Pipeline mencakup pembersihan data, normalisasi, seleksi fitur dengan *Principal Component Analysis* (PCA) dan korelasi Pearson, pemodelan dengan *Multilayer Perceptron* (MLP), serta analisis kepentingan fitur dengan algoritma Garson.




Figure 1: Dataset C-MAPSS — makalah referensi (Saxena et al., PHM08)

2 Dataset C-MAPSS

2.1 Deskripsi Dataset

Dataset C-MAPSS terdiri dari empat sub-dataset dengan karakteristik yang berbeda, memungkinkan evaluasi model pada tingkat kompleksitas yang bervariasi.

Table 1: Karakteristik empat sub-dataset C-MAPSS

Sub-dataset	Kondisi Operasi	Mode Kerusakan	Jumlah Mesin		Jumlah Baris	
			Train	Test	Train	Test
FD001	1	HPC	100	100	20.631	13.096
FD002	6	HPC	260	259	53.759	33.991
FD003	1	HPC + Fan	100	100	24.720	16.596
FD004	6	HPC + Fan	248	248	61.249	41.214

Setiap baris data terdiri dari 26 kolom: `unit_number`, `time_cycles`, tiga *operational settings*,

dan 21 sensor. Data *train* mencatat siklus penuh hingga kegagalan; data *test* dipotong sebelum kegagalan. File `RUL_FDxxx.txt` berisi RUL sebenarnya pada titik pemotongan sebagai kunci jawaban evaluasi.

2.2 Struktur HDF5

Seluruh data disimpan dalam format HDF5 menggunakan satu skrip konsolidasi `build_cmapss_complete.py` yang membaca langsung dari file `.txt` NASA tanpa file perantara.




Figure 2: Struktur HDF5 lengkap `cmapss_FD001.h5` ditampilkan di HDFView

Struktur HDF5 per file mencakup: `/train/data` (32 kolom), `/train/data_norm`, `/test/data` (29 kolom), `/test/data_norm`, `/RUL/data`, `/norm_params`, `/correlation`, `/engine_summary`, dan `/pca`.

3 Pembersihan Data (*Data Cleaning*)

3.1 Identifikasi Sensor Konstan

Tahap pembersihan data berfokus pada identifikasi sensor yang tidak membawa informasi degradasi. Lima metode statistik digunakan secara bersamaan:

1. **Standar Deviasi** — sensor dengan $\text{std} \approx 0$ bersifat konstan
2. **Koefisien Variasi (CV)** — $\text{cv} = \sigma/|\mu|$, nilai $< 0,001$ tidak informatif
3. **Korelasi Pearson** — mengukur hubungan linear dengan RUL
4. **Korelasi Spearman** — mengukur hubungan monoton dengan RUL
5. **Mutual Information** — menangkap hubungan non-linear dengan RUL

3.2 Hasil Analisis

Sensor dengan $\text{std} = 0$ menghasilkan nilai Pearson dan Spearman tidak terdefinisi (`NaN`) — bukti matematis paling kuat untuk eliminasi. Tabel 2 merangkum sensor yang dieliminasi per

sub-dataset.

Table 2: Sensor yang dieliminasi per sub-dataset (std = 0)

Sub-dataset	Jumlah Dihapus	Sensor
FD001	6	T2, P2, epr, farB, Nf_dmd, PCNfR_dmd
FD002	0	(tidak ada — 6 kondisi operasi menyebabkan semua sensor bervariasi)
FD003	5	T2, P2, farB, Nf_dmd, PCNfR_dmd
FD004	0	(tidak ada)

Perbedaan antara FD001/FD003 (1 kondisi) dan FD002/FD004 (6 kondisi) menunjukkan bahwa sensor seperti T2 dan P2 bersifat konstan dalam satu kondisi operasi, namun bervariasi antar kondisi. FD003 mempertahankan **epr** karena memiliki std = 0,0035 (kecil namun bukan nol) akibat mode kerusakan HPC+Fan.

4 Normalisasi

4.1 Metode Z-Score Berbasis *Healthy Cycles*

Normalisasi menggunakan *z-score* per kondisi operasi, dengan parameter μ dan σ dihitung hanya dari siklus *healthy* ($RUL_raw \geq 125$):

$$z = \frac{x - \mu_c}{\sigma_c} \quad (1)$$

di mana subscript c menunjukkan kondisi operasi. Pendekatan ini memastikan nilai $z = 0$ merepresentasikan kondisi mesin sehat, sehingga penyimpangan dari nol mencerminkan degradasi.

Parameter normalisasi disimpan dalam `/norm_params` dengan dimensi ($n_kondisi \times n_sensor$): FD001/FD003 berukuran $(1, n_s)$ dan FD002/FD004 berukuran $(6, n_s)$.

Data *test* dinormalisasi menggunakan parameter dari data *train* — bukan parameter data *test* itu sendiri — untuk menghindari *data leakage*.

5 Seleksi Fitur

5.1 Korelasi Pearson

Matriks korelasi Pearson dihitung dari `train_normalized` untuk seluruh 21 sensor. Sensor konstan menghasilkan baris dan kolom NaN.

sensor	T2	T24	T30	T50	P2	P15	P30	Nf	Nc	epr	Ps30	phi	NRf	NRC	BPR	farB	htBleed	Nf_dmd	PCNR_dmd	W31	W32
T2																					
T24																					
T30																					
T50																					
P2																					
P15																					
P30																					
Nf																					
Nc																					
epr																					
Ps30																					
phi																					
NRf																					
NRC																					
BPR																					
farB																					
htBleed																					
Nf_dmd																					
PCNR_dmd																					
W31																					
W32																					

Figure 3: Matriks korelasi Pearson antar sensor (FD001) — merah = korelasi positif kuat, biru = negatif kuat

Pasangan sensor dengan $|r| > 0,90$ seperti Nf–NRf ($r = 0,83$) dan Nc–NRC ($r = 0,96$) mengindikasikan redundansi informasi — motivasi utama penggunaan PCA.

5.2 Principal Component Analysis (PCA)

PCA diterapkan pada data *train_normalized* untuk mereduksi dimensi. Jumlah komponen dipilih berdasarkan **Opsi B**: pertahankan komponen dengan varians individual $\geq 5\%$.

Table 3: Hasil PCA per sub-dataset — jumlah komponen (Opsi B)

Sub-dataset	Sensor	Komponen	Varians Kumulatif	Komponen Dominan
FD001	15	2	82,9%	PC1: speed sensors (52,4%)
FD002	21	4	74,8%	PC1: speed (41,6%), PC3: epr (8,4%)
FD003	16	3	87,8%	PC1: speed (60,2%)
FD004	21	3	77,5%	PC1: speed (48,4%)

Variance summary			
component	individual variance	cumulative variance	kept?
PC1	52.42%	52.42%	YES
PC2	30.52%	82.94%	YES
PC3	1.97%	84.91%	no
PC4	1.85%	86.76%	no
PC5	1.74%	88.50%	no
PC6	1.60%	90.09%	no
PC7	1.57%	91.66%	no
PC8	1.43%	93.10%	no
PC9	1.34%	94.43%	no
PC10	1.21%	95.64%	no
PC11	1.10%	96.74%	no
PC12	1.01%	97.76%	no
PC13	0.93%	98.68%	no
PC14	0.82%	99.50%	no
PC15	0.50%	100.00%	no

Figure 4: Tabel varians PCA dan matriks *eigenvectors* (FD002) — PC3 didominasi oleh **epr** dengan *loading* 0,94

Temuan penting: pada FD002, PC3 hampir seluruhnya dijelaskan oleh **epr** (*loading* = 0,940). Sensor ini konstan di FD001 namun bervariasi antar kondisi operasi di FD002, sehingga terisolasi menjadi komponen tersendiri.

6 Model Artificial Neural Network

6.1 Arsitektur dan Konfigurasi


Model *Multilayer Perceptron* (MLP) dengan arsitektur: $input \rightarrow 64 \rightarrow 32 \rightarrow 1$. Fungsi aktivasi ReLU pada lapisan tersembunyi, output linear.

Table 4: Konfigurasi pelatihan model ANN

Parameter	Nilai
Arsitektur	$input \rightarrow 64 \rightarrow 32 \rightarrow 1$
Aktivasi	ReLU (tersembunyi), Linear (output)
Loss	MSE
Optimizer	Adam, $lr = 10^{-3}$
Epoch	500
Batch size	512
Target	RUL_capped (cap = 125 siklus)

6.2 Desain Eksperimen Benchmark

Benchmark dirancang sebagai eksperimen 2-faktor: **Faktor 1** — sub-dataset (FD001–FD004); **Faktor 2** — tipe input (PCA vs. sensor ternormalisasi). Total 8 model dilatih.



```

C-MAPSS ANN Benchmark
Architecture: input → 64 → 32 → 1
Epochs: 500 Batch: 512 LR: 0.001
Runs: 4 sub-datasets × 2 input types = 8 models

[FD001_PCA]
input_dim=2 train=20,631 test=13,096 features=PC1, PC2
epoch 100/500 rmse=17.7636
epoch 200/500 rmse=17.7218
epoch 300/500 rmse=17.7104
epoch 400/500 rmse=17.6964
epoch 500/500 rmse=17.6865
RMSE=17.7975 MAE=12.5539 NASA=815.29

[FD001_NORM]
input_dim=15 train=20,631 test=13,096 features=T24, T30, T50, P15...
epoch 100/500 rmse=17.7670
epoch 200/500 rmse=17.5486
epoch 300/500 rmse=17.4384
epoch 400/500 rmse=17.3664
epoch 500/500 rmse=17.2995
RMSE=18.2114 MAE=13.5197 NASA=928.52

```

Figure 5: Output terminal pelatihan model ANN — FD001 PCA dan NORM

6.3 Hasil Benchmark

Table 5: Hasil benchmark 8 model — RMSE, MAE, dan NASA Score

Sub-dataset	Input	Dim	RMSE	MAE	NASA Score
FD001	PCA	2	17,80	12,55	815
FD001	NORM	15	18,21	13,52	929
FD002	PCA	4	29,30	20,52	14.423
FD002	NORM	21	29,45	20,73	12.990
FD003	PCA	3	21,87	16,17	2.650
FD003	NORM	16	20,16	15,28	1.783
FD004	PCA	3	30,59	23,28	9.267
FD004	NORM	21	29,68	22,38	7.157

sub_dataset	input_type	input_dim	n_features	train_rows	test_engines	epochs	rmse	mae	nasa_score
FD001	PCA	2	2	20631	100	500	17.7975	12.5539	815.2936
FD001	NORM	15	15	20631	100	500	18.2114	13.5197	928.5185
FD002	PCA	4	4	53759	259	500	29.301	20.5168	14423.2351
FD002	NORM	21	21	53759	259	500	29.4486	20.7347	12989.7386
FD003	PCA	3	3	24720	100	500	21.8702	16.1735	2649.6629
FD003	NORM	16	16	24720	100	500	20.1572	15.2807	1783.1105
FD004	PCA	3	3	61249	248	500	30.5893	23.2834	9266.6769
FD004	NORM	21	21	61249	248	500	29.6773	22.3752	7156.8189

Figure 6: File `summary.csv` hasil benchmark dibuka di LibreOffice Calc

6.4 Analisis Hasil

Pengaruh Faktor 1 (sub-dataset): Kompleksitas kondisi operasi menjadi faktor dominan. Sub-dataset dengan 1 kondisi (FD001, FD003) menghasilkan RMSE $\approx$ 18–22, sedangkan sub-

dataset dengan 6 kondisi (FD002, FD004) menghasilkan RMSE $\approx 29\text{--}31$ — peningkatan sekitar 60%.

Pengaruh Faktor 2 (tipe input):

- **1 kondisi operasi:** PCA mengungguli NORM pada FD001 dan FD002 (berdasarkan RMSE). Kompresi PCA menghilangkan *noise* secara efektif ketika masalah sederhana.
- **6 kondisi operasi:** NORM mengungguli PCA pada FD003 dan FD004. Sensor penuh mempertahankan informasi spesifik kondisi yang hilang dalam kompresi PCA.

NASA Score FD002 yang tinggi (14.423 vs. ~ 815 untuk FD001) mengindikasikan banyak prediksi *late* — model cenderung lebih-estimasi RUL pada data dengan 6 kondisi operasi yang kompleks.

7 Analisis Garson

7.1 Algoritma Garson

Algoritma Garson [2] menghitung kepentingan relatif setiap fitur input berdasarkan bobot jaringan yang telah dilatih. Untuk arsitektur dua lapisan tersembunyi (W_1, W_2, W_3):

$$q_1[i, j] = \frac{|W_1[j, i]|}{\sum_k |W_1[j, k]|}, \quad q_2[j, m] = \frac{|W_2[m, j]|}{\sum_k |W_2[m, k]|} \quad (2)$$

$$r[i, m] = \sum_j q_1[i, j] \cdot q_2[j, m], \quad s[i] = \sum_m r[i, m] \cdot |W_3[m]|, \quad \text{importance}[i] = \frac{s[i]}{\sum_k s[k]} \quad (3)$$

7.2 Hasil Analisis Garson




Figure 7: Output terminal algoritma Garson — top 5 fitur per model

Table 6: Lima fitur terpenting per model (algoritma Garson)

Model	Fitur #1	Top 5 Fitur
FD001_PCA	PC1 (51,7%)	PC1 51,7% — PC2 48,3%
FD001_NORM	P15 (22,3%)	P15 22,3% — NRc 6,7% — phi 6,6% — Nc 5,8% — Ps30 5,7%
FD002_PCA	PC4 (31,0%)	PC4 31,0% — PC2 24,3% — PC3 22,6% — PC1 22,1%
FD002_NORM	T2 (10,1%)	T2 10,1% — PCNFR_dmd 7,1% — P2 6,8% — farB 6,5% — NRc 5,7%
FD003_PCA	PC2 (37,9%)	PC2 37,9% — PC3 35,7% — PC1 26,5%
FD003_NORM	P15 (14,7%)	P15 14,7% — epr 8,0% — phi 6,8% — P30 6,4% — NRc 6,3%
FD004_PCA	PC2 (42,3%)	PC2 42,3% — PC3 31,8% — PC1 26,0%
FD004_NORM	T2 (9,9%)	T2 9,9% — P2 9,3% — P15 8,4% — Ps30 5,5% — phi 5,2%

7.3 Perbandingan Tiga Metode Seleksi Fitur

Table 7: Perbandingan kepentingan sensor berdasarkan tiga metode (FD001)

Sensor	Pearson vs RUL	PCA Loading	Garson (ANN)	Interpretasi
Ps30	-0,70	tinggi	sedang	Konsisten — penting
T50	-0,68	tinggi	sedang	Konsisten — penting
P30	+0,66	tinggi	sedang	Konsisten — penting
P15	-0,13	rendah	tinggi	Perbedaan — ANN mendeteksi sinyal non-linear
NRf	-0,56	sedang	rendah	Sebagian konsisten

Temuan penting: sensor **P15** memiliki korelasi Pearson rendah (-0,13) dan kontribusi PCA rendah, namun Garson menetapkan sebagai fitur terpenting (22,3%) pada model FD001_NORM. Hal ini mengindikasikan bahwa ANN mampu mengeksplorasi hubungan non-linear yang tidak terdeteksi oleh Pearson dan PCA.

Pada FD002_NORM, sensor **T2**, **P2**, **PCNfR_dmd** dan **farB** — yang dieliminasi dari FD001 karena std = 0 — justru muncul sebagai fitur terpenting. Ini mengkonfirmasi bahwa eliminasi sensor harus dilakukan per sub-dataset, bukan secara universal.

8 Kesimpulan

Pipeline analitik lengkap telah berhasil diimplementasikan untuk prediksi RUL mesin turbofan menggunakan dataset C-MAPSS, dengan temuan utama sebagai berikut:

1. **Kompleksitas kondisi operasi** adalah faktor dominan yang memengaruhi akurasi prediksi. Sub-dataset dengan 6 kondisi (FD002, FD004) menghasilkan RMSE ≈ 29 –31 dibandingkan 18–22 untuk sub-dataset 1 kondisi.
2. **Tipe input optimal bergantung pada kompleksitas dataset:** PCA lebih baik untuk dataset sederhana (1 kondisi), sensor penuh lebih baik untuk dataset kompleks (6 kondisi). Ini konsisten dengan teori — PCA membuang 17% varians yang justru relevan ketika sinyal degradasi tersebar di banyak kondisi.
3. **Algoritma Garson** mengungkap hubungan non-linear yang tidak terdeteksi oleh Pearson dan PCA — khususnya sensor P15 yang rendah secara linear namun tinggi secara kepentingan ANN.
4. **Eliminasi sensor harus bersifat per sub-dataset:** sensor konstan di FD001 (T2, P2) menjadi fitur terpenting di FD002, karena variasi antar kondisi operasi mengandung informasi degradasi.

References

- [1] A. Saxena, K. Goebel, D. Simon, N. Eklund, “Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation,” *Proceedings of the 1st International Conference on Prognostics and Health Management (PHM08)*, Denver, CO, 2008.

- [2] G.D. Garson, “Interpreting Neural Network Connection Weights,” *AI Expert*, vol. 6, no. 4, pp. 46–51, 1991.