



UNIVERSITAS INDONESIA

Fakultas Teknik – Departemen Teknik Mesin

PREDIKSI *REMAINING USEFUL LIFE*
MESIN TURBOFAN MENGGUNAKAN
ARTIFICIAL NEURAL NETWORK
PADA DATASET C-MAPSS

Mata Kuliah:

Data Analitik

Dosen Pengampu:

Dr. Eng. Sholahudin, S.T., M.Sc.

Disusun Oleh:

2506565466 Luqman Alifio Arhab
2506565414 Azfa Rhazasta Abiandra
2506565401 Adamsyah Haryo Saksono
2506565433 Epsiarto Rizqi Nurwijayadi

DEPARTEMEN TEKNIK MESIN
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

2026

Contents

1	Pendahuluan	3
1.1	Latar Belakang	3
1.2	Tujuan	3
1.3	Alur Pipeline	3
2	Dataset C-MAPSS	4
2.1	Deskripsi Dataset	4
2.2	Kolom dan Sensor	5
2.3	Struktur HDF5	7
3	Pembersihan Data	8
3.1	Identifikasi Sensor Tidak Informatif	8
3.2	Tabel Statistik Sensor FD001	9
3.3	Hasil Eliminasi per Sub-dataset	9
4	Normalisasi	10
4.1	Formula Z-Score	10
4.2	Mengapa Hanya Siklus Sehat	10
4.3	Mengapa Per Kondisi, Bukan Global	11
4.4	Penerapan ke Data Test	11
5	Seleksi Fitur	11
5.1	Korelasi Pearson	11
5.2	Principal Component Analysis (PCA)	12
5.2.1	Varians yang Dijelaskan	12
5.2.2	Pemilihan Jumlah Komponen — Opsi B	12
5.2.3	Interpretasi Eigenvectors	13
6	Pipeline Spreadsheet	13
7	Model Artificial Neural Network	15
7.1	Arsitektur MLP	15
7.2	Target: RUL Capped	15
7.3	Desain Eksperimen Benchmark	16
7.4	Hasil Benchmark	17
7.5	Analisis Hasil	17
7.6	Loss Curve	19
8	Analisis Garson	19
8.1	Algoritma	19
8.2	Hasil per Model	20
8.3	Perbandingan Tiga Metode Seleksi Fitur	21

9 Keterbatasan dan Pengembangan	21
9.1 Keterbatasan	21
9.2 Pengembangan yang Memungkinkan	21
10 Kesimpulan	22

1 Pendahuluan

1.1 Latar Belakang

Prediksi *Remaining Useful Life* (RUL) merupakan komponen kunci dalam sistem *Prognostics and Health Management* (PHM) peralatan mekanik. Dengan mengetahui sisa umur pakai suatu komponen sebelum kegagalan terjadi, jadwal perawatan dapat dioptimalkan sehingga mengurangi biaya *downtime* tak terencana dan risiko kegagalan mendadak yang berpotensi berbahaya.

Pada mesin turbofan penerbangan, degradasi komponen seperti *High Pressure Compressor* (HPC) dan *Fan* berlangsung secara gradual dan tercermin dalam perubahan pola sensor. Tantangan utamanya adalah memisahkan sinyal degradasi dari variasi kondisi operasi yang normal.

1.2 Tujuan

Laporan ini mendokumentasikan pipeline analitik lengkap untuk prediksi RUL menggunakan dataset C-MAPSS (NASA), mencakup:

1. Pembersihan data berbasis analisis statistik
2. Normalisasi dengan metode *z-score* berbasis siklus sehat
3. Seleksi fitur menggunakan korelasi Pearson dan PCA
4. Pemodelan dengan *Multilayer Perceptron* (MLP)
5. Analisis kepentingan fitur dengan algoritma Garson




Figure 1: Hierarki PHM — laporan ini berfokus pada lapisan *Prognostics* (prediksi RUL)

1.3 Alur Pipeline




Figure 2: Alur pipeline analitik lengkap

2 Dataset C-MAPSS

2.1 Deskripsi Dataset

Dataset C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) dipublikasikan oleh NASA pada konferensi PHM 2008 [1]. Dataset ini mensimulasikan degradasi mesin turbofan dari kondisi sehat hingga kegagalan pada berbagai skenario operasi.




Figure 3: Makalah referensi dataset C-MAPSS (Saxena et al., PHM08)

Dataset dapat diunduh dari repositori NASA PCoE:

<https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/>

Empat sub-dataset tersedia dengan karakteristik berbeda, memungkinkan evaluasi model pada tingkat kompleksitas yang bervariasi:

Dataset	Conditions op settings	Fault modes degraded modules	Train trajectories	Test trajectories	RUL file ground truth
FD001 easiest	1 sea level only	1 HPC degradation	100	100	RUL_FD001.txt 100 values
FD002 medium	6 alt / Mach / TRA	1 HPC degradation	260	259	RUL_FD002.txt 259 values
FD003 medium	1 sea level only	2 HPC + Fan	100	100	RUL_FD003.txt 100 values
FD004 hardest	6 alt / Mach / TRA	2 HPC + Fan	248	249	RUL_FD004.txt 249 values

Conditions axis: FD001/FD003 (1 condition) vs FD002/FD004 (6 conditions)
 Fault mode axis: FD001/FD002 (1 fault mode) vs FD003/FD004 (2 fault modes)

Files per sub-dataset: train_FDxxx.txt test_FDxxx.txt RUL_FDxxx.txt (12 files total)
 26 columns in train/test (unit, cycle, 3 op settings, 21 sensors). RUL file: one integer per engine.

Figure 4: Matriks karakteristik empat sub-dataset C-MAPSS — FD001 termudah (1 kondisi, 1 mode kerusakan) hingga FD004 tersulit (6 kondisi, 2 mode kerusakan)

2.2 Kolom dan Sensor




Figure 5: Skema mesin turbofan C-MAPSS — sensor mengukur kondisi di sepanjang aliran udara dari inlet hingga exhaust; HPC adalah komponen yang terdegradasi

Setiap baris data terdiri dari 26 kolom tanpa *header*:

Table 1: Deskripsi 26 kolom data C-MAPSS

Kolom	Nama	Keterangan
1	<code>unit_number</code>	Nomor identitas mesin
2	<code>time_cycles</code>	Siklus operasi (bertambah 1 tiap baris)
3–5	<code>op_setting_1/2/3</code>	Pengaturan kondisi operasi
6–26	sensor (21 buah)	Pembacaan sensor fisik mesin

Konsep *Remaining Useful Life* pada dataset ini bekerja sebagai berikut: data *train* mencatat siklus penuh hingga kegagalan sehingga RUL dapat dihitung langsung ($RUL = t_{\max} - t_{\text{saat ini}}$). Data *test* dipotong sebelum kegagalan, dan file `RUL_FDxxx.txt` berisi RUL sebenarnya pada titik pemotongan sebagai kunci jawaban evaluasi.




Figure 6: Hubungan antara file train, test, dan RUL — test dipotong sebelum kegagalan; RUL file berisi kunci jawaban

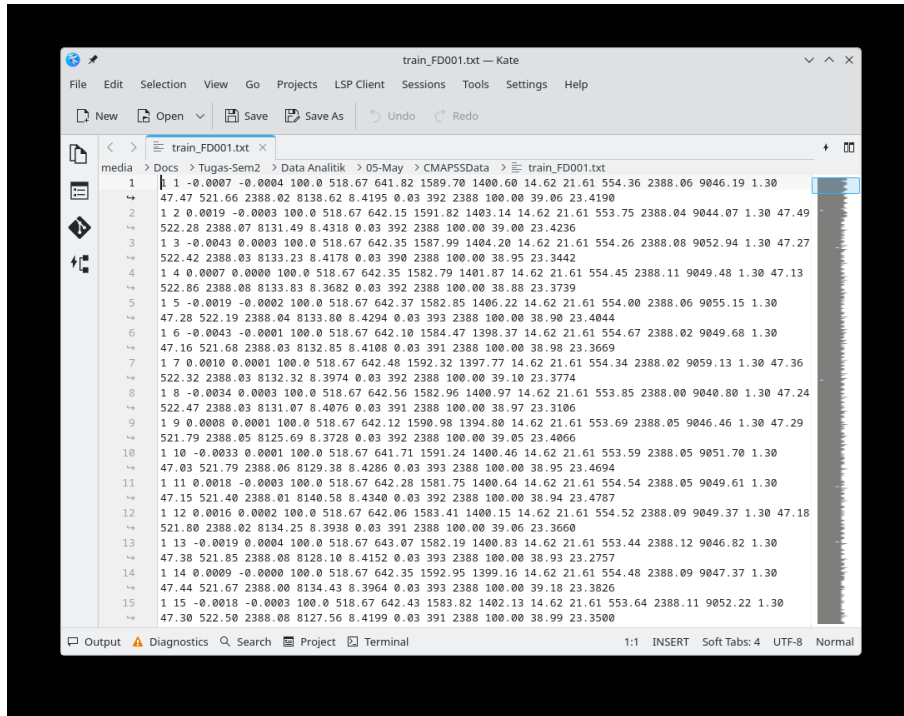



Figure 7: Tampilan raw data train_FD001.txt — 26 kolom tanpa header

2.3 Struktur HDF5

Seluruh data disimpan dalam format HDF5 menggunakan satu skrip konsolidasi `build_cmapss_complete.py` yang membaca langsung dari file `.txt` NASA tanpa file perantara. Satu file HDF5 per sub-dataset dihasilkan.



(a) Vanilla HDF5

(b) + Normalisasi

(c) + Korelasi + PCA

Figure 8: Evolusi struktur HDF5 dari vanilla hingga lengkap

Struktur HDF5 final per file:

Table 2: Struktur HDF5 lengkap `cmapss_FDxxx.h5`

Path	Dimensi	Isi
/train/data	$(n, 32)$	26 kolom raw + 6 kolom komputasi
/train/data_norm	(n, n_s)	Sensor ternormalisasi
/test/data	$(n, 29)$	26 raw + 3 kolom komputasi
/test/data_norm	(n, n_s)	Sensor ternormalisasi (param train)
/RUL/data	$(n_e, 4)$	unit, rul, last_cycle, total_life_est
/norm_params	(n_c, n_s)	Parameter normalisasi per kondisi
/correlation/matrix	$(21, 21)$	Matriks korelasi Pearson
/engine_summary/data	$(n_e, 11)$	Ringkasan per mesin train
/pca/params	—	Eigenvectors dan varians
/pca/train	$(n, 3 + k)$	Meta + skor PC (train)
/pca/test	$(n, 3 + k)$	Meta + skor PC (test)

n_s : jumlah sensor; n_e : jumlah mesin; n_c : jumlah kondisi; k : jumlah komponen PCA

3 Pembersihan Data

3.1 Identifikasi Sensor Tidak Informatif

Lima metode statistik digunakan secara bersamaan untuk mengidentifikasi sensor yang tidak membawa informasi degradasi:

1. **Standar Deviasi (std)** — sensor dengan $\text{std} \approx 0$ bersifat konstan
2. **Koefisien Variasi (CV)** — $\text{CV} = \sigma/|\mu|$; nilai $< 0,001$ menunjukkan variasi yang tidak signifikan
3. **Korelasi Pearson** dengan RUL — hubungan linear; nilai ≈ 0 berarti tidak ada hubungan linear
4. **Korelasi Spearman** dengan RUL — hubungan monoton; lebih robust terhadap non-linearitas
5. **Mutual Information (MI)** dengan RUL — menangkap hubungan non-linear; nilai ≈ 0 berarti tidak ada hubungan sama sekali

3.2 Tabel Statistik Sensor FD001

Table 3: Statistik lengkap sensor FD001 — sensor dengan std = 0 ditandai (†)

Sensor	Mean	Std	CV	Pearson	Spearman	MI	Drop
T2 [†]	518.67	0.000	0.000	NaN	NaN	0.000	✓
T24	642.68	0.500	0.001	−0.607	−0.629	0.342	
T30	1590.5	6.131	0.004	−0.585	−0.606	0.306	
T50	1408.9	9.001	0.006	−0.679	−0.702	0.467	
P2 [†]	14.62	0.000	0.000	NaN	NaN	0.006	✓
P15	21.61	0.001	0.000	−0.128	−0.128	0.006	✓
P30	553.37	0.885	0.002	+0.657	+0.679	0.425	
Nf	2388.1	0.071	0.000	−0.564	−0.574	0.258	
Nc	9065.2	22.08	0.002	−0.390	−0.322	0.222	
epr [†]	1.30	0.000	0.000	NaN	NaN	0.000	✓
Ps30	47.54	0.267	0.006	−0.696	−0.718	0.507	
phi	521.41	0.738	0.001	+0.672	+0.693	0.442	
NRf	2388.1	0.072	0.000	−0.563	−0.573	0.262	
NRc	8143.8	19.08	0.002	−0.307	−0.202	0.225	
BPR	8.44	0.038	0.004	−0.643	−0.666	0.390	
farB [†]	0.03	0.000	0.000	NaN	NaN	0.000	✓
htBleed	393.21	1.549	0.004	−0.606	−0.629	0.328	
Nf_dmd [†]	2388.0	0.000	0.000	NaN	NaN	0.000	✓
PCNfR_dmd [†]	100.00	0.000	0.000	NaN	NaN	0.000	✓
W31	38.82	0.181	0.005	+0.629	+0.653	0.367	
W32	23.29	0.108	0.005	+0.636	+0.657	0.380	

[†] Konstan (std = 0); Pearson/Spearman tidak terdefinisi (NaN); dieliminasi

Untuk sub-dataset lain, analisis serupa dilakukan. Hasilnya: FD002 dan FD004 tidak mengeliminasi sensor apapun karena variasi antar 6 kondisi operasi membuat semua sensor bervariasi. FD003 mengeliminasi 5 sensor yang sama dengan FD001, kecuali **epr** yang memiliki std = 0,0035 (kecil namun tidak nol) akibat mode kerusakan HPC+Fan.

3.3 Hasil Eliminasi per Sub-dataset

Table 4: Sensor yang dieliminasi per sub-dataset

Sub-dataset	Dihapus	Sensor
FD001	6	T2, P2, epr, farB, Nf_dmd, PCNfR_dmd
FD002	0	(tidak ada — semua sensor bervariasi antar 6 kondisi)
FD003	5	T2, P2, farB, Nf_dmd, PCNfR_dmd
FD004	0	(tidak ada)

4 Normalisasi

4.1 Formula Z-Score

Normalisasi *z-score* mentransformasi setiap pembacaan sensor menjadi jumlah standar deviasi dari nilai referensi:

$$z = \frac{x - \mu_c}{\sigma_c} \quad (1)$$

di mana μ_c dan σ_c adalah mean dan standar deviasi untuk kondisi operasi c .

4.2 Mengapa Hanya Siklus Sehat

Parameter μ_c dan σ_c dihitung hanya dari siklus dengan $RUL_raw \geq 125$ (*healthy cycles*). Alasannya: jika parameter dihitung dari seluruh siklus termasuk yang terdegradasi, maka nilai $z = 0$ tidak lagi merepresentasikan kondisi sehat — melainkan rata-rata dari sehat hingga menjelang gagal. Akibatnya, sinyal degradasi menjadi kabur.

Dengan menggunakan siklus sehat sebagai referensi:

- Siklus sehat $\rightarrow z \approx 0$
- Siklus terdegradasi $\rightarrow z$ menyimpang dari 0
- Penyimpangan dari 0 = sinyal degradasi yang dapat dipelajari model




Figure 9: Pipeline normalisasi per kondisi — raw sensor $\rightarrow$ kluster kondisi $\rightarrow$ statistik healthy $\rightarrow$ nilai ternormalisasi

4.3 Mengapa Per Kondisi, Bukan Global

Pada FD002 dan FD004 terdapat 6 kondisi operasi (ketinggian dan kecepatan penerbangan berbeda). Sensor seperti T2 (*fan inlet temperature*) memiliki nilai ≈ 518 R pada kondisi 1 namun ≈ 445 R pada kondisi lain — perbedaan 73 R ini bukan akibat degradasi, melainkan perbedaan kondisi operasi.

Normalisasi global akan menganggap selisih ini sebagai penyimpangan dan mengaburkan sinyal degradasi yang sebenarnya. Normalisasi per kondisi menghilangkan efek kondisi operasi terlebih dahulu, menyisakan hanya sinyal degradasi.

4.4 Penerapan ke Data Test

Data *test* dinormalisasi menggunakan parameter yang dihitung dari data *train*:

$$z_{\text{test}} = \frac{x_{\text{test}} - \mu_{c, \text{train}}}{\sigma_{c, \text{train}}} \quad (2)$$

Menggunakan parameter *test* sendiri (*data leakage*) adalah keliru karena pada kondisi *deployment* nyata, distribusi data masa depan tidak diketahui. Parameter harus dibekukan dari data *train*.

5 Seleksi Fitur

5.1 Korelasi Pearson

Matriks korelasi Pearson dihitung dari *train_normalized* untuk seluruh 21 sensor. Sensor konstan menghasilkan baris dan kolom NaN.

sensor	T2	T24	T30	T50	P2	P15	P30	Nf	Nc	epr	Ps30	phi	NRf	NRc	BPR	farB	htBleed	Nf_dmd	PCNIR_dmd	W31	W32
T2																					
T24		1.00	0.60	0.71		0.13	-0.70	0.66	0.27		0.74	-0.72	0.66	0.18	0.68		0.63			-0.66	-0.67
T30		0.60	1.00	0.68		0.12	-0.66	0.60	0.32		0.70	-0.68	0.60	0.24	0.64		0.60			-0.63	-0.63
T50		0.71	0.68	1.00		0.15	-0.79	0.75	0.30		0.83	-0.82	0.75	0.19	0.76		0.70			-0.75	-0.75
P2					1.00																
P15		0.13	0.12	0.15		1.00	-0.16	0.15	0.02		0.16	-0.16	0.16	0.00	0.15		0.13			-0.14	-0.14
P30		-0.70	-0.66	-0.79		-0.16	1.00	-0.77	-0.22		-0.82	0.81	-0.76	-0.11	-0.75		-0.69			0.74	0.74
Nf		0.66	0.60	0.75		0.15	-0.77	1.00	-0.03		0.78	-0.79	0.83	-0.14	0.70		0.63			-0.69	-0.69
Nc		0.27	0.32	0.30		0.02	-0.22	-0.03	1.00		0.27	-0.21	-0.03	0.96	0.29		0.34			-0.29	-0.29
epr										1.00											
Ps30		0.74	0.70	0.83		0.16	-0.82	0.78	0.27		1.00	-0.85	0.78	0.16	0.78		0.72			-0.77	-0.77
phi		-0.72	-0.68	-0.82		-0.16	0.81	-0.79	-0.21		-0.85	1.00	-0.79	-0.10	-0.77		-0.70			0.75	0.76
NRf		0.66	0.60	0.75		0.16	-0.76	0.83	-0.03		0.78	-0.79	1.00	-0.15	0.70		0.63			-0.69	-0.69
NRc		0.18	0.24	0.19		0.00	-0.11	-0.14	0.96		0.16	-0.10	-0.15	1.00	0.19		0.25			-0.19	-0.19
BPR		0.68	0.64	0.76		0.15	-0.75	0.70	0.29		0.78	-0.77	0.70	0.19	1.00		0.67			-0.71	-0.70
farB																1.00					
htBleed		0.63	0.60	0.70		0.13	-0.69	0.63	0.34		0.72	-0.70	0.63	0.25	0.67		1.00			-0.65	-0.66
Nf_dmd																		1.00			
PCNIR_dmd																			1.00		
W31		-0.66	-0.63	-0.75		-0.14	0.74	-0.69	-0.29		-0.77	0.75	-0.69	-0.19	-0.71		-0.65			1.00	0.69
W32		-0.67	-0.63	-0.75		-0.14	0.74	-0.69	-0.29		-0.77	0.76	-0.69	-0.19	-0.70		-0.66			0.69	1.00

Figure 10: Matriks korelasi Pearson antar sensor (FD001) di spreadsheet v5

Dari matriks korelasi, teridentifikasi:

- **Sensor kuat negatif vs RUL:** Ps30 ($-0,70$), T50 ($-0,68$), phi ($+0,67$) — sensor ini paling relevan untuk prediksi

- **Redundansi:** Nf–NRf ($r = 0,83$), Nc–NRc ($r = 0,96$) — pasangan ini membawa informasi yang hampir sama, motivasi utama PCA

5.2 Principal Component Analysis (PCA)

5.2.1 Varians yang Dijelaskan

PCA diterapkan pada `train_normalized`. Komponen diurutkan dari yang menjelaskan varians terbesar. Tabel 5 menunjukkan varians individual dan kumulatif.

Table 5: Varians PCA per sub-dataset (8 komponen pertama)

Sub-dataset	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
FD001	52,4%	30,5%	2,0%	1,8%	1,7%	1,6%	1,6%	1,4%
FD002	41,6%	19,5%	8,4%	5,3%	4,8%	2,3%	2,1%	1,9%
FD003	60,2%	20,4%	7,2%	3,9%	1,7%	1,1%	1,0%	0,9%
FD004	48,4%	20,9%	8,1%	4,3%	2,7%	2,4%	2,0%	1,7%

Pada FD001 terdapat *scree cliff* setelah PC2: PC1 = 52,4% dan PC2 = 30,5%, kemudian PC3 hanya 2,0%. Ini menunjukkan dua komponen pertama mendominasi informasi.

5.2.2 Pemilihan Jumlah Komponen — Opsi B

Kriteria pemilihan: pertahankan komponen dengan varians individual $\geq 5\%$. Alasan: komponen di bawah 5% sebagian besar merupakan *noise* sisa setelah informasi utama terekstrak.

Table 6: Jumlah komponen PCA yang dipertahankan (Opsi B, varians $\geq 5\%$)

Sub-dataset	Sensor	Komponen	Varians Kumulatif	Komponen yang Dipertahankan
FD001	15	2	82,9%	PC1, PC2
FD002	21	4	74,8%	PC1, PC2, PC3, PC4
FD003	16	3	87,8%	PC1, PC2, PC3
FD004	21	3	77,5%	PC1, PC2, PC3

5.2.3 Interpretasi Eigenvectors

Variance summary			
component	individual variance	cumulative variance	kept?
PC1	52.42%	52.42%	YES
PC2	30.52%	82.94%	YES
PC3	1.97%	84.91%	no
PC4	1.85%	86.76%	no
PC5	1.74%	88.50%	no
PC6	1.60%	90.09%	no
PC7	1.57%	91.66%	no
PC8	1.43%	93.10%	no
PC9	1.34%	94.43%	no
PC10	1.21%	95.64%	no
PC11	1.10%	96.74%	no
PC12	1.01%	97.76%	no
PC13	0.93%	98.68%	no
PC14	0.82%	99.50%	no
PC15	0.50%	100.00%	no

Figure 11: Tabel varians dan matriks *eigenvectors* pada spreadsheet v6 (FD002)

Interpretasi fisik komponen FD002:

- **PC1** (41,6%): didominasi Nf, NRf, Nc, NRc — merepresentasikan *overall engine speed state*
- **PC2** (19,5%): kontras NRc/Nc positif vs Ps30/BPR/T50 negatif — merepresentasikan *compressor loading condition*
- **PC3** (8,4%): epr dengan *loading* = 0,940 — hampir seluruhnya merupakan *engine pressure ratio*; terisolasi karena bervariasi berbeda dari sensor lain antar kondisi operasi
- **PC4** (5,3%): farB positif vs Nc/NRc negatif — merepresentasikan *fuel combustion efficiency*

6 Pipeline Spreadsheet

Paralel dengan pipeline HDF5, seluruh data dan analisis juga didokumentasikan dalam format spreadsheet LibreOffice Calc (kompatibel Excel) melalui enam versi iteratif.





Figure 12: Struktur direktori spreadsheet — enam versi iteratif (v1–v6)

Table 7: Evolusi spreadsheet v1–v6 dan sheet yang ditambahkan

Versi	Sheet Baru	Isi
v1	train	Data raw 26 kolom
v2	test, RUL	Data test + RUL dengan last_cycle dan total_life
v3	—	Penambahan kolom komputasi (condition_index, RUL_raw, dll.)
v4	train_normalized	Sensor ternormalisasi (z-score per kondisi)
v5	test_normalized, stats, correlation, engine_summary	Normalisasi test, statistik per sensor, matriks ringkasan mesin
v6	pca_params, pca_train, pca_test	Parameter PCA (eigenvectors, varians), skor PCA dan test



(b) Sheet `pca_train (v6)` — skor PC per siklus

7 Model Artificial Neural Network

Model *Multilayer Perceptron* (MLP) dengan arsitektur tiga lapisan:

$$\text{input} \xrightarrow{W_1} 64 \xrightarrow{\text{ReLU}} W_2 \rightarrow 32 \xrightarrow{\text{ReLU}} W_3 \rightarrow 1 \quad (3)$$

Parameter	Nilai
Arsitektur	input $\rightarrow 64 \rightarrow 32 \rightarrow 1$
Aktivasi	ReLU (tersembunyi), Linear (output)
Loss	MSE (<i>Mean Squared Error</i>)
Optimizer	Adam, lr = 10^{-3}
Epoch	500
Batch size	512

Target pelatihan menggunakan **RUL_capped** dengan cap = 125 siklus, bukan **RUL_raw**. Alasannya: pada siklus awal ketika mesin masih sehat, pembacaan sensor hampir identik meskipun nilai **RUL_raw** berbeda (mis. 300 vs 250 siklus). Model tidak dapat membedakan keduanya dari sensor. Cap 125 menyederhanakan target: semua siklus sehat diperlakukan setara, dan model difokuskan pada fase degradasi di mana sinyal sensor benar-benar bervariasi.




Figure 14: RUL raw vs RUL capped (cap = 125) — fase sehat diratakan, model difokuskan pada fase degradasi

7.3 Desain Eksperimen Benchmark

Benchmark dirancang sebagai eksperimen 2-faktor:

- **Faktor 1** — Sub-dataset: FD001, FD002, FD003, FD004
- **Faktor 2** — Tipe input: PCA (skor PC) vs NORM (semua sensor ternormalisasi)
- **Total:** $4 \times 2 = 8$ model




Figure 15: Struktur direktori hasil benchmark — 8 subfolder + `summary.csv`

7.4 Hasil Benchmark

Table 9: Hasil benchmark 8 model (500 epoch, batch 512)

Sub-dataset	Input	Dim	RMSE	MAE	NASA Score
FD001	PCA	2	17,80	12,55	815
FD001	NORM	15	18,21	13,52	929
FD002	PCA	4	29,30	20,52	14.423
FD002	NORM	21	29,45	20,73	12.990
FD003	PCA	3	21,87	16,17	2.650
FD003	NORM	16	20,16	15,28	1.783
FD004	PCA	3	30,59	23,28	9.267
FD004	NORM	21	29,68	22,38	7.157

sub_dataset	input_type	input_dim	n_features	train_rows	test_engines	epochs	rmse	mae	nasa_score
FD001	PCA	2	2	20631	100	500	17.7975	12.5539	815.2936
FD001	NORM	15	15	20631	100	500	18.2114	13.5197	928.5185
FD002	PCA	4	4	53759	259	500	29.301	20.5168	14423.2351
FD002	NORM	21	21	53759	259	500	29.4486	20.7347	12989.7386
FD003	PCA	3	3	24720	100	500	21.8702	16.1735	2649.6629
FD003	NORM	16	16	24720	100	500	20.1572	15.2807	1783.1105
FD004	PCA	3	3	61249	248	500	30.5893	23.2834	9266.6769
FD004	NORM	21	21	61249	248	500	29.6773	22.3752	7156.8189

Figure 16: File `summary.csv` hasil benchmark di LibreOffice Calc

7.5 Analisis Hasil

Pengaruh Faktor 1 — Kompleksitas Sub-dataset:

Table 10: RMSE rata-rata per sub-dataset (rerata PCA dan NORM)

	FD001	FD003	FD002	FD004
Kondisi operasi	1		6	
Mode kerusakan	HPC	HPC+Fan	HPC	HPC+Fan
RMSE rata-rata	18,0	21,0	29,4	30,1

Sub-dataset dengan 6 kondisi operasi menghasilkan RMSE $\approx 60\%$ lebih tinggi dibandingkan 1 kondisi. Ini adalah faktor dominan yang melebihi pengaruh tipe input.

Pengaruh Faktor 2 — Tipe Input:

Terdapat interaksi antara kedua faktor: PCA lebih baik pada dataset *sederhana* (FD001, FD002 berdasarkan RMSE), sedangkan NORM lebih baik pada dataset *kompleks* (FD003, FD004). Hal ini konsisten dengan teori: kompresi PCA membuang 17% varians yang justru relevan ketika terdapat kompleksitas lebih tinggi (dua mode kerusakan atau 6 kondisi operasi).

NASA Score FD002 yang Anomali:

NASA score FD002 (14.423) jauh lebih tinggi dibandingkan FD001 (815). NASA score menggunakan penalti eksponensial asimetris: prediksi *late* (overestimasi RUL) dihukum lebih berat

($e^{d/13}$) dibandingkan prediksi *early* ($e^{d/10}$).




Figure 17: Kurva penalti NASA Score — prediksi *late* ($d > 0$, merah) dihukum lebih berat dari prediksi *early* ($d < 0$, biru)

Pada FD002 dengan 6 kondisi operasi yang kompleks, model cenderung overestimasi RUL pada banyak mesin, mengakibatkan akumulasi penalti eksponensial yang tinggi.

7.6 Loss Curve




Figure 18: *Training loss (RMSE) per epoch — FD001 NORM*

Kurva *loss* FD001 menunjukkan konvergensi yang hampir penuh setelah ≈ 200 epoch; epoch 200–500 hanya menghasilkan penurunan kecil ($17,77 \rightarrow 17,30$). Model PCA konvergen lebih cepat karena dimensi input lebih kecil (2 vs 15 fitur).

8 Analisis Garson

8.1 Algoritma

Algoritma Garson [2] menghitung kepentingan relatif setiap fitur input berdasarkan bobot jaringan yang telah dilatih. Untuk arsitektur dua lapisan tersembunyi dengan matriks bobot W_1 , W_2 , W_3 :

$$q_1[i, j] = \frac{|W_1[j, i]|}{\sum_k |W_1[j, k]|} \quad q_2[j, m] = \frac{|W_2[m, j]|}{\sum_k |W_2[m, k]|} \quad (4)$$

$$r[i, m] = \sum_j q_1[i, j] \cdot q_2[j, m] \quad s[i] = \sum_m r[i, m] \cdot |W_3[m]| \quad (5)$$

$$\text{importance}[i] = \frac{s[i]}{\sum_k s[k]} \quad (6)$$

Hasilnya adalah satu skor kepentingan per fitur input, dengan total 100%.

8.2 Hasil per Model




Figure 19: Output terminal algoritma Garson — top 5 fitur FD001 dan FD002

Table 11: Lima fitur terpenting per model (algoritma Garson)

Model	Fitur #1	Top 5 Fitur (kepentingan %)
FD001_PCA	PC1 (51,7%)	PC1 51,7% — PC2 48,3%
FD001_NORM	P15 (22,3%)	P15 22,3% — NRc 6,7% — phi 6,6% — Nc 5,8% — Ps30 5,7%
FD002_PCA	PC4 (31,0%)	PC4 31,0% — PC2 24,3% — PC3 22,6% — PC1 22,1%
FD002_NORM	T2 (10,1%)	T2 10,1% — PCNfR_dmd 7,1% — P2 6,8% — farB 6,5% — NRc 5,7%
FD003_PCA	PC2 (37,9%)	PC2 37,9% — PC3 35,7% — PC1 26,5%
FD003_NORM	P15 (14,7%)	P15 14,7% — epr 8,0% — phi 6,8% — P30 6,4% — NRc 6,3%
FD004_PCA	PC2 (42,3%)	PC2 42,3% — PC3 31,8% — PC1 26,0%
FD004_NORM	T2 (9,9%)	T2 9,9% — P2 9,3% — P15 8,4% — Ps30 5,5% — phi 5,2%

8.3 Perbandingan Tiga Metode Seleksi Fitur

Table 12: Perbandingan kepentingan sensor berdasarkan tiga metode (FD001)

Sensor	Pearson	PCA Loading	Garson	Interpretasi
Ps30	-0,70	tinggi	sedang	Konsisten — penting secara linear
T50	-0,68	tinggi	sedang	Konsisten — penting secara linear
P30	+0,66	tinggi	sedang	Konsisten — penting secara linear
P15	-0,13	rendah	tinggi	Perbedaan — ANN menemukan sinyal non-linear
NRf	-0,56	sedang	rendah	Sebagian konsisten

Metode yang digunakan: Pearson = korelasi linear dengan RUL; PCA = kontribusi variansi; Garson = kepentingan da

Temuan utama dari perbandingan tiga metode:

1. **P15** memiliki korelasi Pearson rendah (-0,13) dan kontribusi PCA rendah, namun Garson menetapkan sebagai fitur terpenting (22,3%) pada FD001_NORM. Ini mengindikasikan ANN mengeksplorasi hubungan non-linear yang tidak terdeteksi oleh Pearson dan PCA.
2. **FD002_NORM**: T2, P2, PCNfR_dmd, farB — sensor yang dieliminasi dari FD001 karena std = 0 — muncul sebagai fitur terpenting di FD002. Hal ini mengkonfirmasi eliminasi sensor harus dilakukan *per sub-dataset*, bukan secara universal.
3. **Konsistensi Ps30 dan T50**: keduanya penting menurut ketiga metode, menjadikannya kandidat fitur paling andal untuk prediksi RUL secara umum.

9 Keterbatasan dan Pengembangan

9.1 Keterbatasan

1. **Arsitektur MLP sederhana**: model feedforward tidak memanfaatkan dependensi temporal antar siklus. Setiap siklus diperlakukan independen, padahal degradasi adalah proses sekuensial.
2. **Dataset simulasi**: C-MAPSS adalah data simulasi, bukan data mesin nyata. Pola degradasi pada mesin nyata mungkin lebih kompleks dan tidak sebersih data simulasi.
3. **Tanpa regularisasi**: model tidak menggunakan *dropout* atau regularisasi lain. Gap antara *train RMSE* (17,3) dan *test RMSE* (18,2) pada FD001 mengindikasikan *overfitting* ringan.
4. **Garson untuk dua lapisan tersembunyi**: algoritma Garson orisinal dirancang untuk satu lapisan tersembunyi. Ekstensi ke dua lapisan yang digunakan di sini kurang didukung literatur dibandingkan versi satu lapisan.

9.2 Pengembangan yang Memungkinkan

1. **LSTM / GRU**: memanfaatkan urutan temporal siklus untuk prediksi yang lebih akurat
2. **Dropout regularisasi**: mengurangi *overfitting* pada dataset dengan sensor penuh (NORM)
3. **Normalisasi per kondisi lebih ketat**: menggunakan *condition subtraction* sebelum PCA untuk dataset 6 kondisi

10 Kesimpulan

Pipeline analitik lengkap untuk prediksi RUL mesin turbopan C-MAPSS telah berhasil diimplementasikan. Temuan utama:

1. **Kompleksitas kondisi operasi adalah faktor dominan.** Sub-dataset 6 kondisi (FD002, FD004) menghasilkan RMSE $\approx 60\%$ lebih tinggi dari sub-dataset 1 kondisi (FD001, FD003), terlepas dari tipe input yang digunakan.
2. **Tipe input optimal bergantung pada kompleksitas.** PCA lebih baik untuk dataset sederhana (1 kondisi); sensor ternormalisasi penuh lebih baik untuk dataset kompleks (2 mode kerusakan atau 6 kondisi).
3. **Algoritma Garson mengungkap sinyal non-linear.** Sensor P15 — yang memiliki korelasi Pearson rendah dan kontribusi PCA rendah — terbukti menjadi fitur terpenting menurut Garson pada FD001_NORM, menunjukkan ANN mampu mengeksplorasi hubungan non-linear.
4. **Eliminasi sensor harus per sub-dataset.** Sensor konstan di FD001 (T2, P2) menjadi fitur terpenting di FD002 karena variasi antar kondisi operasi mengandung informasi degradasi.

References

- [1] A. Saxena, K. Goebel, D. Simon, N. Eklund, “Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation,” *Proc. 1st Int. Conf. Prognostics and Health Management (PHM08)*, Denver, CO, 2008.
- [2] G.D. Garson, “Interpreting Neural Network Connection Weights,” *AI Expert*, vol. 6, no. 4, pp. 46–51, 1991.