



UNIVERSITAS INDONESIA

Fakultas Teknik – Departemen Teknik Mesin

PREDIKSI *REMAINING USEFUL LIFE*
MESIN TURBOFAN MENGGUNAKAN
ARTIFICIAL NEURAL NETWORK
PADA DATASET C-MAPSS

Mata Kuliah:

Data Analitik

Dosen Pengampu:

Dr. Eng. Sholahudin, S.T., M.Sc.

Disusun Oleh:

2506565466 Luqman Alifio Arhab
2506565414 Azfa Rhazasta Abiandra
2506565401 Adamsyah Haryo Saksono
2506565433 Epsiarto Rizqi Nurwijayadi

DEPARTEMEN TEKNIK MESIN
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

2026

Contents

1	Pendahuluan	2
1.1	Latar Belakang	2
1.2	Tujuan	2
1.3	Alur Pipeline	2
2	Dataset C-MAPSS	3
2.1	Deskripsi Dataset	3
2.2	Struktur Mesin dan Sensor	4
2.3	Konsep RUL dan Struktur File	4
2.4	Motivasi: Mengapa Prediksi RUL Sulit	5
2.5	Struktur HDF5	5
3	Pembersihan Data	6
3.1	Metode	6
3.2	Hasil Analisis FD001	7
3.3	Perbandingan Antar Sub-dataset	7
4	Normalisasi	8
4.1	Metode Z-Score Berbasis Siklus Sehat	8
4.2	Mengapa Siklus Sehat Saja	9
4.3	Mengapa Per Kondisi, Bukan Global	9
4.4	Penerapan ke Data Test	9
5	Seleksi Fitur	10
5.1	Korelasi Pearson Antar Sensor	10
5.2	Principal Component Analysis (PCA)	11
5.2.1	Varians yang Dijelaskan	11
5.2.2	Interpretasi PCA dalam Ruang 2D	12
5.2.3	Interpretasi Eigenvectors	13
5.3	Pipeline Spreadsheet	13
6	Model <i>Artificial Neural Network</i>	14
6.1	Arsitektur MLP	14
6.2	Target: RUL Capped	15
6.3	Metrik Evaluasi	15
6.4	Desain Eksperimen Benchmark	16
6.5	Hasil Training	16
6.6	Hasil Benchmark	17
6.7	Analisis Faktor	18
7	Analisis Garson	18
7.1	Algoritma	18
7.2	Model PCA — Kepentingan Komponen	19

7.3	Model NORM — Kepentingan Sensor	20
7.4	Perbandingan Tiga Metode	21
8	Keterbatasan dan Pengembangan	21
8.1	Keterbatasan	21
8.2	Pengembangan yang Memungkinkan	22
9	Kesimpulan	22

1 Pendahuluan

1.1 Latar Belakang

Prediksi *Remaining Useful Life* (RUL) merupakan komponen kunci dalam sistem *Prognostics and Health Management* (PHM). Dengan mengetahui sisa umur pakai komponen sebelum kegagalan, jadwal perawatan dapat dioptimalkan sehingga mengurangi biaya *downtime* tak terencana dan risiko kegagalan mendadak yang berpotensi berbahaya.




Figure 1: Hierarki PHM — laporan ini berfokus pada lapisan *Prognostics* (prediksi RUL), lapisan kedua dari atas

Sistem PHM terdiri dari beberapa lapisan mulai dari *sensing* (pengumpulan data sensor) hingga *decision making* (perencanaan perawatan). Laporan ini berfokus pada lapisan **Prognostics** — menjawab pertanyaan “berapa lama lagi komponen ini akan bertahan?”

Pada mesin turbofan penerbangan, degradasi komponen seperti *High Pressure Compressor* (HPC) dan *Fan* berlangsung secara gradual dan tercermin dalam perubahan pola sensor. Tantangan utamanya adalah memisahkan sinyal degradasi dari variasi kondisi operasi yang normal.

1.2 Tujuan

1. Membersihkan data dengan analisis korelasi sensor terhadap output (RUL)
2. Menormalisasi data dengan metode *z-score* berbasis siklus sehat
3. Memilih fitur menggunakan korelasi Pearson dan PCA
4. Membangun dan membandingkan model MLP pada empat sub-dataset
5. Menganalisis kepentingan fitur dengan algoritma Garson

1.3 Alur Pipeline




Figure 2: Alur pipeline analitik lengkap

2 Dataset C-MAPSS

2.1 Deskripsi Dataset

Dataset C-MAPSS (*Commercial Modular Aero-Propulsion System Simulation*) dipublikasikan oleh NASA [1] dan tersedia di:

<https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/>

Dataset	Conditions op settings	Fault modes degraded modules	Train trajectories	Test trajectories	RUL file ground truth
FD001 easiest	1 sea level only	1 HPC degradation	100	100	RUL_FD001.txt 100 values
FD002 medium	6 alt / Mach / TRA	1 HPC degradation	260	259	RUL_FD002.txt 259 values
FD003 medium	1 sea level only	2 HPC + Fan	100	100	RUL_FD003.txt 100 values
FD004 hardest	6 alt / Mach / TRA	2 HPC + Fan	248	249	RUL_FD004.txt 249 values

↑
increasing difficulty
↓

Conditions axis: FD001/FD003 (1 condition) vs FD002/FD004 (6 conditions)
 Fault mode axis: FD001/FD002 (1 fault mode) vs FD003/FD004 (2 fault modes)

Files per sub-dataset: train_FDxxx.txt test_FDxxx.txt RUL_FDxxx.txt (12 files total)
 26 columns in train/test (unit, cycle, 3 op settings, 21 sensors). RUL file: one integer per engine.

Figure 3: Matriks karakteristik empat sub-dataset C-MAPSS — FD001 (termudah: 1 kondisi, 1 mode kerusakan) hingga FD004 (tersulit: 6 kondisi, 2 mode kerusakan)

Empat sub-dataset tersedia dengan tingkat kompleksitas berbeda. FD001 dan FD003 memiliki satu kondisi operasi (sea level), sedangkan FD002 dan FD004 memiliki enam kondisi operasi berbeda (altitude, Mach number, throttle resolver angle). Mode kerusakan HPC terdapat di semua sub-dataset; FD003 dan FD004 menambahkan kerusakan Fan secara bersamaan.

2.2 Struktur Mesin dan Sensor




Figure 4: Skema mesin turbofan C-MAPSS — 21 sensor mengukur kondisi di sepanjang aliran udara dari inlet hingga exhaust; HPC adalah komponen yang mengalami degradasi pada semua sub-dataset

Setiap baris data terdiri dari 26 kolom tanpa *header*: `unit_number`, `time_cycles`, tiga *op_settings*, dan 21 sensor. Sensor mengukur suhu, tekanan, kecepatan poros, dan aliran udara di berbagai titik sepanjang mesin.

2.3 Konsep RUL dan Struktur File




Figure 5: Hubungan antara file train, test, dan RUL — data *train* mencatat siklus penuh hingga kegagalan sehingga RUL dapat dihitung langsung; data *test* dipotong di siklus t^* dan `RUL_FDxxx.txt` berisi kunci jawaban

Data *train* mencatat siklus penuh hingga kegagalan sehingga RUL dapat dihitung: $RUL = t_{\max} - t_{\text{saat ini}}$. Data *test* dipotong sebelum kegagalan — ini adalah kondisi *deployment* nyata di

mana kita tidak tahu kapan mesin akan gagal. File `RUL_FDxxx.txt` berisi satu integer per mesin test sebagai kunci jawaban untuk evaluasi model.

2.4 Motivasi: Mengapa Prediksi RUL Sulit




Figure 6: Trajektori degradasi sensor FD001 untuk lima mesin representatif — setiap garis adalah satu mesin dari siklus pertama hingga kegagalan; sensor Ps30, T50, phi, dan P30 menunjukkan drift yang jelas menjelang akhir umur mesin

Gambar 6 menunjukkan mengapa prediksi RUL adalah masalah yang tidak trivial. Setiap mesin memiliki umur total berbeda (x-axis berakhir di titik berbeda). Sensor mulai dengan nilai yang relatif stabil di fase sehat, kemudian mulai menyimpang secara gradual di fase degradasi. Penyimpangan inilah yang harus dipelajari model untuk memprediksi berapa siklus tersisa.

2.5 Struktur HDF5

Seluruh data disimpan dalam format HDF5 menggunakan satu skrip konsolidasi `build_cmapss_complete.py` yang membaca langsung dari file `.txt` NASA tanpa file perantara.




Figure 7: Evolusi struktur HDF5 dari vanilla hingga lengkap

3 Pembersihan Data

3.1 Metode

Pembersihan data dilakukan dengan menganalisis korelasi setiap sensor terhadap output (RUL). Sensor yang tidak membawa informasi degradasi dieliminasi menggunakan lima metode statistik secara bersamaan:

1. **Standar Deviasi (std)** — sensor konstan ($\text{std} = 0$) tidak bervariasi sama sekali
2. **Koefisien Variasi (CV)** — $\text{CV} = \sigma/|\mu|$; nilai sangat kecil menunjukkan variasi tidak signifikan
3. **Korelasi Pearson vs RUL** — mengukur hubungan *linear* sensor terhadap output; nilai ≈ 0 berarti tidak ada hubungan linear
4. **Korelasi Spearman vs RUL** — mengukur hubungan *monoton*; lebih robust terhadap non-linearitas
5. **Mutual Information (MI) vs RUL** — menangkap hubungan non-linear; nilai ≈ 0 berarti tidak ada hubungan sama sekali

3.2 Hasil Analisis FD001

Table 1: Statistik sensor FD001 terhadap output RUL — sensor dengan std = 0 ditandai (†)

Sensor	Mean	Std	CV	Pearson	Spearman	MI	Hapus
T2 [†]	518.67	0.000	0.000	NaN	NaN	0.000	✓
T24	642.68	0.500	0.001	−0.607	−0.629	0.342	
T30	1590.5	6.131	0.004	−0.585	−0.606	0.306	
T50	1408.9	9.001	0.006	−0.679	−0.702	0.467	
P2 [†]	14.62	0.000	0.000	NaN	NaN	0.006	✓
P15	21.61	0.001	0.000	−0.128	−0.128	0.006	✓
P30	553.37	0.885	0.002	+0.657	+0.679	0.425	
Nf	2388.1	0.071	0.000	−0.564	−0.574	0.258	
Nc	9065.2	22.08	0.002	−0.390	−0.322	0.222	
epr [†]	1.30	0.000	0.000	NaN	NaN	0.000	✓
Ps30	47.54	0.267	0.006	−0.696	−0.718	0.507	
phi	521.41	0.738	0.001	+0.672	+0.693	0.442	
NRf	2388.1	0.072	0.000	−0.563	−0.573	0.262	
NRc	8143.8	19.08	0.002	−0.307	−0.202	0.225	
BPR	8.44	0.038	0.004	−0.643	−0.666	0.390	
farB [†]	0.03	0.000	0.000	NaN	NaN	0.000	✓
htBleed	393.21	1.549	0.004	−0.606	−0.629	0.328	
Nf_dmd [†]	2388.0	0.000	0.000	NaN	NaN	0.000	✓
PCNfR_dmd [†]	100.00	0.000	0.000	NaN	NaN	0.000	✓
W31	38.82	0.181	0.005	+0.629	+0.653	0.367	
W32	23.29	0.108	0.005	+0.636	+0.657	0.380	

[†] std = 0: Pearson/Spearman tidak terdefinisi (NaN); dieliminasi

Sensor dengan std = 0 menghasilkan nilai Pearson dan Spearman **NaN** — bukti matematis paling kuat bahwa sensor tersebut tidak dapat berkorelasi dengan apapun. Sensor P15 dieliminasi karena CV ≈ 0 dan Pearson hanya $-0,13$ (hampir tidak ada korelasi dengan RUL).

3.3 Perbandingan Antar Sub-dataset

Table 2: Sensor yang dieliminasi per sub-dataset

Sub-dataset	Dihapus	Sensor
FD001	6	T2, P2, epr, farB, Nf_dmd, PCNfR_dmd
FD002	0	(tidak ada — semua sensor bervariasi antar 6 kondisi operasi)
FD003	5	T2, P2, farB, Nf_dmd, PCNfR_dmd
FD004	0	(tidak ada)

FD002 dan FD004 tidak mengeliminasi sensor apapun karena variasi antar 6 kondisi operasi membuat semua sensor bervariasi. Sensor seperti T2 bersifat konstan dalam satu kondisi (FD001) namun bervariasi antar kondisi (FD002). FD003 mempertahankan **epr** karena memiliki std

= 0,0035 — kecil namun tidak nol — akibat mode kerusakan HPC+Fan yang berbeda dari FD001.

4 Normalisasi

4.1 Metode Z-Score Berbasis Siklus Sehat




Figure 8: Pipeline normalisasi per kondisi — parameter μ_c dan σ_c dihitung dari siklus sehat ($RUL_raw \geq 125$) lalu diterapkan ke seluruh data termasuk siklus terdegradasi

Normalisasi menggunakan formula *z-score*:

$$z = \frac{x - \mu_{c, \text{healthy}}}{\sigma_{c, \text{healthy}}} \quad (1)$$

di mana μ_c dan σ_c dihitung hanya dari siklus dengan $RUL_raw \geq 125$ (*healthy cycles*) untuk kondisi operasi c .

4.2 Mengapa Siklus Sehat Saja




Figure 9: Perbandingan normalisasi global vs *healthy-only* untuk sensor Ps30 pada tiga mesin (Engine 1, 31, 77) FD001 — garis putus-putus vertikal menandai awal fase degradasi per mesin (saat RUL_{raw} turun di bawah 125)

Gambar 9 menunjukkan perbedaan kedua metode pada sensor Ps30 untuk tiga mesin sekaligus. Setiap garis berwarna merepresentasikan satu mesin: Engine 1 (biru, 192 siklus), Engine 31 (hijau, ≈200 siklus), dan Engine 77 (coklat, 154 siklus). Garis putus-putus vertikal menandai kapan fase degradasi dimulai untuk masing-masing mesin.

Global z-score (kiri): ketiga mesin mulai pada nilai z yang tersebar (-1 hingga $+1$). Artinya, mesin yang sehat pun sudah memiliki $z \neq 0$ hanya karena μ dipengaruhi oleh siklus terdegradasi di seluruh dataset. Referensi nol tidak merepresentasikan kondisi sehat.

Healthy-only z-score (kanan): ketiga mesin mulai mendekati $z \approx 0$ di siklus awal, lalu secara konsisten *drift* ke atas seiring degradasi. Penyimpangan dari nol adalah sinyal degradasi yang akan dipelajari model ANN.

4.3 Mengapa Per Kondisi, Bukan Global

Pada FD002 dan FD004 terdapat 6 kondisi operasi. Sensor seperti T2 bernilai ≈ 518 R pada kondisi 1 namun ≈ 445 R pada kondisi lain — selisih 73 R ini bukan degradasi, melainkan perbedaan kondisi operasi. Normalisasi global akan mengaburkan sinyal degradasi dengan variasi kondisi. Normalisasi per kondisi menghilangkan efek kondisi terlebih dahulu, menyisakan hanya sinyal degradasi.

4.4 Penerapan ke Data Test

Data *test* dinormalisasi menggunakan parameter dari data *train*:

$$z_{\text{test}} = \frac{x_{\text{test}} - \mu_{c, \text{train, healthy}}}{\sigma_{c, \text{train, healthy}}} \quad (2)$$

Menggunakan parameter *test* sendiri merupakan *data leakage* karena pada kondisi *deployment* nyata, distribusi data masa depan tidak diketahui saat pelatihan.

5 Seleksi Fitur

5.1 Korelasi Pearson Antar Sensor




Figure 10: Matriks korelasi Pearson antar 15 sensor aktif (FD001, dihitung dari `train_normalized`) — sel putih = sensor konstan yang dieliminasi; blok merah gelap menunjukkan pasangan sensor yang sangat berkorelasi ($Nc-NRc$ $r = 0,96$, $Nf-NRf$ $r = 0,83$)

Gambar 10 menunjukkan matriks korelasi Pearson. Sel putih adalah baris/kolom sensor yang dieliminasi ($std = 0$). Blok merah gelap pada pasangan $Nc-NRc$ ($r = 0,96$) dan $Nf-NRf$ ($r = 0,83$) menunjukkan redundansi tinggi — kedua sensor dalam pasangan tersebut membawa informasi yang hampir identik. Inilah motivasi utama penggunaan PCA: membuang redundansi sambil mempertahankan informasi.

5.2 Principal Component Analysis (PCA)

5.2.1 Varians yang Dijelaskan




Figure 11: *Scree plot* PCA FD001 (15 sensor) — batang biru = komponen yang dipertahankan (varians individual $\geq 5\%$); garis teal = varians kumulatif; *cliff* setelah PC2 menunjukkan PC3 dan seterusnya hanya mengandung *noise*

Gambar 11 menunjukkan *scree plot* — grafik varians individual per komponen. Terdapat *scree cliff* yang sangat tajam setelah PC2: PC1 = 52,4%, PC2 = 30,5%, kemudian PC3 tiba-tiba turun ke 2,0%. Ini berarti hampir semua informasi bermakna sudah terangkum dalam dua komponen pertama. Komponen PC3 dan seterusnya sebagian besar merupakan *noise* sisa.

Table 3: Ringkasan PCA per sub-dataset (Ops B: varians $\geq 5\%$)

Sub-dataset	Sensor	Komponen	Varians Kumulatif	Komponen Dominan
FD001	15	2	82,9%	PC1: speed (52,4%), PC2: pressure contrast
FD002	21	4	74,8%	PC1: speed (41,6%), PC3: epr alone (8,4%)
FD003	16	3	87,8%	PC1: speed (60,2%)
FD004	21	3	77,5%	PC1: speed (48,4%)

5.2.2 Interpretasi PCA dalam Ruang 2D



Figure 12: Scatter plot PC1 vs PC2 diwarnai berdasarkan nilai RUL — hijau = sehat (RUL tinggi), merah = mendekati gagal (RUL rendah); setiap titik adalah satu siklus mesin dari data *train* FD001 (disubsampel setiap 3 siklus untuk keterbacaan)

Gambar 12 menunjukkan seluruh data *train* FD001 yang sudah dikompresi menjadi 2 angka (PC1 dan PC2) per siklus. Setiap titik adalah satu siklus operasi satu mesin. Warna merepresentasikan RUL sebagai dimensi ketiga (pseudo-3D).

Pola yang terlihat: titik-titik hijau (mesin sehat, RUL tinggi) cenderung berada di sisi kanan (PC1 positif), sedangkan titik-titik merah (mendekati kegagalan, RUL rendah) berada di sisi kiri (PC1 negatif). Ini membuktikan PC1 memang menangkap sinyal degradasi — mesin yang terdegradasi memiliki nilai PC1 yang berbeda dari mesin sehat.

5.2.3 Interpretasi Eigenvectors

Variance summary			
component	individual variance	cumulative variance	kept?
PC1	52.42%	52.42%	YES
PC2	30.52%	82.94%	YES
PC3	1.97%	84.91%	no
PC4	1.85%	86.76%	no
PC5	1.74%	88.50%	no
PC6	1.60%	90.09%	no
PC7	1.57%	91.66%	no
PC8	1.43%	93.10%	no
PC9	1.34%	94.43%	no
PC10	1.21%	95.64%	no
PC11	1.10%	96.74%	no
PC12	1.01%	97.76%	no
PC13	0.93%	98.68%	no
PC14	0.82%	99.50%	no
PC15	0.50%	100.00%	no

Figure 13: Tabel varians dan matriks *eigenvectors* pada spreadsheet v6 (FD002) — PC3 didominasi oleh *epr* dengan *loading* 0,94, mengisolasinya menjadi komponen tersendiri

Interpretasi fisik komponen FD001:

- **PC1** (52,4%): didominasi *Nf*, *NRf*, *Nc*, *NRc* — sensor kecepatan poros; merepresentasikan *overall engine speed state*
- **PC2** (30,5%): kontras antara sensor kecepatan (positif) dan sensor tekanan/suhu (negatif) — merepresentasikan *compressor loading condition*

5.3 Pipeline Spreadsheet

Table 4: Evolusi spreadsheet v3–v6 dan sheet yang ditambahkan

Versi	Sheet Baru	Isi
v3	train, test, RUL	Data raw + kolom komputasi (<i>condition_id</i> , <i>RUL_raw</i> , dll.)
v4	train_normalized	Sensor ternormalisasi (z-score per kondisi, healthy-only)
v5	test_normalized, stats, correlation, engine_summary	Normalisasi test, statistik per sensor, korelasi, ringkasan mesin
v6	pca_params, pca_train, pca_test	Parameter PCA (<i>eigenvectors</i> , <i>varians</i>) + skor PC per lus

Sheet **stats** (v5) — statistik raw dan ternormalisasi

Sheet **pca_train** (v6) — skor PC per siklus

Figure 14: Contoh sheet spreadsheet v5 dan v6 (FD001)

6 Model Artificial Neural Network

6.1 Arsitektur MLP




Figure 15: Arsitektur MLP yang digunakan — tiga lapisan linear dengan aktivasi ReLU pada lapisan tersembunyi dan output linear; contoh input menunjukkan PC1 dan PC2 untuk model PCA

Model *Multilayer Perceptron* (MLP) dengan arsitektur tiga lapisan:

$$\text{input} \xrightarrow{W_1, \text{ReLU}} 64 \xrightarrow{W_2, \text{ReLU}} 32 \xrightarrow{W_3} 1 \quad (3)$$

Table 5: Konfigurasi pelatihan ANN

Parameter	Nilai
Arsitektur	input $\rightarrow 64 \rightarrow 32 \rightarrow 1$
Aktivasi	ReLU (tersembunyi), Linear (output)
Loss	MSE (<i>Mean Squared Error</i>)
Optimizer	Adam, $lr = 10^{-3}$
Epoch	500
Batch size	512
Target	RUL_capped (cap = 125 siklus)

6.2 Target: RUL Capped




Figure 16: RUL raw vs RUL capped (cap = 125) untuk dua mesin dengan umur total berbeda (Engine 1: 192 siklus, Engine 77: 154 siklus) — fase sehat (biru) diratakan ke 125 pada kedua mesin; garis putus-putus menunjukkan kapan degradasi dimulai

Gambar 16 menunjukkan RUL raw (garis putus-putus biru) dan RUL capped (garis solid teal) untuk dua mesin dengan total umur berbeda. Dua mesin ditampilkan untuk membuktikan bahwa cap bekerja *konsisten* terlepas dari panjang hidup mesin: Engine 1 memasuki fase degradasi di siklus ≈ 67 , sedangkan Engine 77 di siklus ≈ 29 . Namun keduanya memiliki RUL_capped = 125 selama fase sehat — model memperlakukan semua mesin sehat secara setara, dan baru belajar dari perbedaan sensor saat degradasi dimulai.

6.3 Metrik Evaluasi

Tiga metrik digunakan untuk evaluasi komprehensif:

- **RMSE** — *root mean square error*; sensitif terhadap *outlier* karena error dikuadratkan
- **MAE** — *mean absolute error*; rata-rata error absolut, lebih robust terhadap *outlier*
- **NASA Score** — skor asimetris PHM08; prediksi *late* dihukum lebih berat (Gambar 17)




Figure 17: Kurva penalti NASA Score — prediksi *early* ($d < 0$, biru, $e^{-d/13} - 1$) dihukum lebih ringan dari prediksi *late* ($d > 0$, merah, $e^{d/10} - 1$) karena prediksi *late* membahayakan keselamatan

Pada Gambar 17, kurva merah (prediksi *late*) memiliki kemiringan lebih curam dari kurva biru (prediksi *early*). Pada error $d = +30$ siklus (terlambat 30 siklus), penaltinya ≈ 10 . Namun pada $d = +50$ siklus, penaltinya sudah ≈ 47 — meningkat secara eksponensial. Ini mencerminkan realitas: memberitahu maskapai bahwa mesin masih aman padahal sebenarnya hampir gagal adalah kesalahan yang jauh lebih berbahaya dari sekadar jadwal perawatan yang terlalu konservatif.

6.4 Desain Eksperimen Benchmark

Benchmark dirancang sebagai eksperimen 2-faktor: **Faktor 1** = sub-dataset (FD001–FD004); **Faktor 2** = tipe input (PCA vs NORM). Total 8 model dilatih dengan konfigurasi identik.

6.5 Hasil Training




Figure 18: Kurva *loss* (training RMSE per epoch) untuk Model PCA (biru solid) dan Model NORM (teal putus-putus) FD001 — PCA konvergen lebih cepat karena dimensi input lebih kecil (2 vs 15 fitur)

Gambar 18 menunjukkan kurva training RMSE selama 500 epoch. Model PCA (2 fitur) konvergen lebih cepat dan mendatar sekitar epoch 200. Model NORM (15 fitur) masih perlahan menurun di epoch 500 — menunjukkan lebih banyak parameter yang perlu dioptimalkan. Kedua model sudah konvergen dengan baik setelah 300 epoch.

6.6 Hasil Benchmark

Table 6: Hasil benchmark 8 model (500 epoch, batch 512)

Sub-dataset	Input	Dim	RMSE	MAE	NASA Score
FD001	PCA	2	17,80	12,55	815
FD001	NORM	15	18,21	13,52	929
FD002	PCA	4	29,30	20,52	14.423
FD002	NORM	21	29,45	20,73	12.990
FD003	PCA	3	21,87	16,17	2.650
FD003	NORM	16	20,16	15,28	1.783
FD004	PCA	3	30,59	23,28	9.267
FD004	NORM	21	29,68	22,38	7.157




Figure 19: True vs Predicted RUL untuk 100 mesin *test* FD001 — setiap titik adalah satu mesin pada siklus terakhir yang terobservasi; garis diagonal putus-putus = prediksi sempurna; titik merah = prediksi *late* (di atas diagonal, berbahaya), titik biru = prediksi *early* (di bawah diagonal, konservatif)

Gambar 19 menampilkan hasil prediksi untuk 100 mesin *test* FD001. Titik yang tepat pada diagonal berarti prediksi sempurna. Titik di atas diagonal (merah) adalah prediksi *late* — model mengatakan mesin masih punya lebih banyak siklus dari kenyataannya. Pola linear (bukan kuadratik atau acak) muncul karena RUL adalah *countdown* linear — target model juga linear, sehingga hubungan prediksi vs aktual ikut menjadi linear.




Figure 20: Distribusi error prediksi ($d = \text{pred} - \text{true}$) untuk 100 mesin test FD001 — distribusi *right-skewed* pada kedua model menunjukkan bias *late prediction*; garis putus-putus vertikal = mean error (bias)

Gambar 20 menunjukkan histogram error. Kedua model memiliki distribusi yang *right-skewed* — lebih banyak mesin dengan error positif (*late*) daripada negatif (*early*). Model PCA memiliki distribusi lebih sempit dan bias lebih kecil, yang menjelaskan NASA Score yang lebih rendah (815 vs 929).

6.7 Analisis Faktor

Faktor 1 — Kompleksitas sub-dataset adalah faktor dominan. Sub-dataset 6 kondisi (FD002, FD004) menghasilkan RMSE $\approx 60\%$ lebih tinggi (≈ 30) dibandingkan 1 kondisi ($\approx 18-21$).

Faktor 2 — Tipe input menunjukkan interaksi dengan Faktor 1: PCA lebih baik pada FD001/FD002 (1 kondisi atau sederhana), sedangkan NORM lebih baik pada FD003/FD004 (kompleks). Kompresi PCA efektif membuang *noise* pada dataset sederhana, namun membuang informasi yang relevan pada dataset kompleks.

7 Analisis Garson

7.1 Algoritma

Algoritma Garson [2] menghitung kepentingan relatif fitur input berdasarkan bobot jaringan terlatih. Untuk arsitektur dua lapisan tersembunyi (W_1, W_2, W_3):

$$q_1[i, j] = \frac{|W_1[j, i]|}{\sum_k |W_1[j, k]|} \quad q_2[j, m] = \frac{|W_2[m, j]|}{\sum_k |W_2[m, k]|} \quad (4)$$

$$r[i, m] = \sum_j q_1[i, j] \cdot q_2[j, m] \quad s[i] = \sum_m r[i, m] \cdot |W_3[m]| \quad (5)$$

$$\text{importance}[i] = \frac{s[i]}{\sum_k s[k]} \quad (6)$$

Hasil adalah satu skor kepentingan per fitur, total 100%.

7.2 Model PCA — Kepentingan Komponen




Figure 21: Kepentingan Garson untuk Model FD001_PCA — PC1 (kecepatan mesin) dan PC2 (kontras tekanan-kecepatan) hampir seimbang di 51,69% vs 48,31%

Model PCA menunjukkan pembagian yang hampir sempurna 50-50 antara PC1 dan PC2. Ini berarti model ANN menggunakan kedua komponen secara setara — PC1 (yang merepresentasikan kecepatan mesin) dan PC2 (yang merepresentasikan kontras tekanan-kecepatan) sama-sama penting untuk prediksi RUL yang akurat.

7.3 Model NORM — Kepentingan Sensor




Figure 22: Kepentingan Garson untuk 15 sensor Model FD001_NORM — P15 mendominasi dengan 22,27% meskipun korelasi Pearson-nya hanya $-0,13$; batang merah = sensor anomali P15

Gambar 22 menunjukkan hasil yang mengejutkan: sensor **P15** mendominasi dengan 22,27% — lebih dari $3\times$ sensor terpenting berikutnya (NRc 6,70%). Hal ini mengejutkan karena korelasi Pearson P15 terhadap RUL hanya $-0,13$ (hampir tidak ada hubungan linear). ANN menemukan hubungan *non-linear* yang tidak terdeteksi oleh metode linear.

7.4 Perbandingan Tiga Metode




Figure 23: Perbandingan kepentingan sensor menggunakan tiga metode (FD001 NORM model) — teal = $|\text{Pearson vs RUL}|$, ungu = $|\text{PCA loading PC1}|$, merah = Garson importance; area diarsir kuning = anomali P15 yang hanya terdeteksi Garson

Gambar 23 adalah visualisasi paling penting dalam laporan ini. Untuk sensor P15 (diarsir kuning): batang teal (Pearson) hampir tidak terlihat, batang ungu (PCA) juga sangat kecil, namun batang merah (Garson) jauh lebih tinggi dari semua sensor lain. Ini adalah bukti visual bahwa ANN menemukan pola non-linear yang tidak dapat dideteksi oleh dua metode seleksi fitur berbasis statistik linear.

Table 7: Perbandingan tiga metode untuk sensor pilihan (FD001)

Sensor	Pearson	PCA Loading	Garson	Interpretasi
Ps30	−0,70	tinggi	sedang	Konsisten — penting secara linear
T50	−0,68	tinggi	sedang	Konsisten — penting secara linear
P30	+0,66	tinggi	sedang	Konsisten — penting secara linear
P15	−0,13	rendah	22,27%	Anomali — ANN menemukan sinyal non-linear
NRf	−0,56	sedang	rendah	Sebagian konsisten

8 Keterbatasan dan Pengembangan

8.1 Keterbatasan

1. **Arsitektur MLP sederhana:** setiap siklus diperlakukan independen tanpa memanfaatkan dependensi temporal
2. **Dataset simulasi:** C-MAPSS adalah data simulasi; degradasi mesin nyata lebih kompleks dan tidak se-linear ini

3. **Tanpa regularisasi:** tidak ada *dropout*; gap antara train RMSE dan test RMSE mengindikasikan *overfitting* ringan
4. **Garson untuk dua lapisan:** algoritma Garson orisinal dirancang untuk satu lapisan tersembunyi; ekstensi ke dua lapisan kurang didukung literatur

8.2 Pengembangan yang Memungkinkan

1. **LSTM/GRU:** memanfaatkan urutan temporal siklus
2. **Dropout:** mengurangi *overfitting*
3. **Normalisasi per kondisi lebih ketat:** terutama untuk FD002/FD004 yang memiliki 6 kondisi operasi

9 Kesimpulan

1. **Kompleksitas kondisi operasi adalah faktor dominan.** Sub-dataset 6 kondisi (FD002, FD004) menghasilkan RMSE $\approx 60\%$ lebih tinggi dari sub-dataset 1 kondisi, terlepas dari tipe input.
2. **Tipe input optimal bergantung pada kompleksitas dataset.** PCA lebih baik untuk dataset sederhana (1 kondisi); sensor penuh lebih baik untuk dataset kompleks (6 kondisi atau 2 mode kerusakan).
3. **Normalisasi healthy-only per kondisi mempertahankan sinyal degradasi.** Terbukti dari Gambar 9: ketiga mesin mulai di $z \approx 0$ dan secara konsisten *drift* seiring degradasi.
4. **Algoritma Garson mengungkap hubungan non-linear.** Sensor P15 — Pearson rendah, PCA loading rendah — terbukti menjadi fitur terpenting menurut Garson (22,27%), menunjukkan ANN mengeksplorasi pola yang tidak terdeteksi metode linear.
5. **Eliminasi sensor harus per sub-dataset.** Sensor konstan di FD001 (T2, P2) menjadi fitur aktif di FD002 karena variasi antar kondisi operasi mengandung informasi degradasi.

References

- [1] A. Saxena, K. Goebel, D. Simon, N. Eklund, “Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation,” *Proc. 1st Int. Conf. Prognostics and Health Management (PHM08)*, Denver, CO, 2008.
- [2] G.D. Garson, “Interpreting Neural Network Connection Weights,” *AI Expert*, vol. 6, no. 4, pp. 46–51, 1991.