



UNIVERSITAS INDONESIA

Fakultas Teknik – Departemen Teknik Mesin

PREDIKSI *REMAINING USEFUL LIFE*
MESIN TURBOFAN MENGGUNAKAN
ARTIFICIAL NEURAL NETWORK
PADA DATASET C-MAPSS FD001

Mata Kuliah:

Data Analitik

Dosen Pengampu:

Dr. Eng. Sholahudin, S.T., M.Sc.

Disusun Oleh:

2506565466 Luqman Alifio Arhab
2506565414 Azfa Rhazasta Abiandra
2506565401 Adamsyah Haryo Saksono
2506565433 Epsiarto Rizqi Nurwijayadi

DEPARTEMEN TEKNIK MESIN
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

2026

Contents

1	Pendahuluan	3
1.1	Latar Belakang	3
1.2	Tujuan	3
1.3	Alur Pipeline	3
2	Dataset C-MAPSS FD001	3
2.1	Deskripsi	4
2.2	Struktur Mesin dan Sensor	4
2.3	Konsep RUL dan File Data	5
2.4	Struktur HDF5	5
3	Pembersihan Data	5
3.1	Metode	6
3.2	Hasil Analisis FD001	6
4	Normalisasi	6
4.1	Metode Z-Score Berbasis Siklus Sehat	7
4.2	Alasan Penggunaan Siklus Sehat	7
4.3	Penerapan ke Data Test	7
5	Seleksi Fitur	8
5.1	Korelasi Pearson Antar Sensor	8
5.2	Principal Component Analysis (PCA)	8
5.2.1	Varians yang Dijelaskan	8
5.2.2	Pemilihan Komponen	8
5.2.3	Interpretasi Eigenvectors	9
5.3	Pipeline Spreadsheet	9
6	Model <i>Artificial Neural Network</i>	10
6.1	Arsitektur dan Konfigurasi	10
6.2	Target: RUL Capped	11
6.3	Dua Model yang Dibandingkan	11
6.4	Hasil	12
6.5	Analisis Hasil	13
7	Analisis Garson	14
7.1	Algoritma	14
7.2	Hasil Model PCA	14
7.3	Hasil Model NORM	15
7.4	Perbandingan Tiga Metode Seleksi Fitur	15
8	Kesimpulan	15

1 Pendahuluan

1.1 Latar Belakang

Prediksi *Remaining Useful Life* (RUL) merupakan komponen kunci dalam sistem *Prognostics and Health Management* (PHM). Dengan mengetahui sisa umur pakai komponen sebelum kegagalan, jadwal perawatan dapat dioptimalkan sehingga mengurangi biaya *downtime* tak terencana dan risiko kegagalan mendadak.




Figure 1: Hierarki PHM — laporan ini berfokus pada lapisan *Prognostics* (prediksi RUL)

Pada mesin turbofan penerbangan, degradasi komponen seperti *High Pressure Compressor* (HPC) berlangsung secara gradual dan tercermin dalam perubahan pola sensor. Laporan ini menggunakan sub-dataset **FD001** dari C-MAPSS NASA: satu kondisi operasi, satu mode kerusakan (HPC), 100 mesin *train*, 100 mesin *test*.

1.2 Tujuan

1. Membersihkan data dengan analisis korelasi sensor terhadap output (RUL)
2. Menormalisasi data dengan metode *z-score* berbasis siklus sehat
3. Memilih fitur menggunakan korelasi Pearson dan PCA
4. Membangun model MLP untuk prediksi RUL
5. Menganalisis kepentingan fitur dengan algoritma Garson

1.3 Alur Pipeline




Figure 2: Alur pipeline analitik

2 Dataset C-MAPSS FD001

2.1 Deskripsi

Dataset C-MAPSS dipublikasikan oleh NASA [1] dan dapat diunduh dari repositori NASA PCoE:

<https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/>

Dataset	Conditions op settings	Fault modes degraded modules	Train trajectories	Test trajectories	RUL file ground truth
FD001 easiest	1 sea level only	1 HPC degradation	100	100	RUL_FD001.txt 100 values
FD002 medium	6 alt / Mach / TRA	1 HPC degradation	260	259	RUL_FD002.txt 259 values
FD003 medium	1 sea level only	2 HPC + Fan	100	100	RUL_FD003.txt 100 values
FD004 hardest	6 alt / Mach / TRA	2 HPC + Fan	248	249	RUL_FD004.txt 249 values

↑ Increasing difficulty

Conditions axis: FD001/FD003 (1 condition) vs FD002/FD004 (6 conditions)
 Fault mode axis: FD001/FD002 (1 fault mode) vs FD003/FD004 (2 fault modes)

Files per sub-dataset: train_FDxxx.txt test_FDxxx.txt RUL_FDxxx.txt (12 files total)
 26 columns in train/test (unit, cycle, 3 op settings, 21 sensors). RUL file: one integer per engine.

Figure 3: Matriks karakteristik empat sub-dataset C-MAPSS — laporan ini menggunakan **FD001** (termudah: 1 kondisi, 1 mode kerusakan)

FD001 terdiri dari 20.631 baris data *train* (100 mesin, siklus penuh hingga kegagalan) dan 13.096 baris *test* (100 mesin, dipotong sebelum kegagalan). File `RUL_FD001.txt` berisi 100 nilai RUL sebenarnya pada titik pemotongan sebagai kunci jawaban evaluasi.

2.2 Struktur Mesin dan Sensor




Figure 4: Skema mesin turbofan C-MAPSS — 21 sensor mengukur kondisi di sepanjang aliran udara; HPC adalah komponen yang mengalami degradasi

Setiap baris data terdiri dari 26 kolom: `unit_number`, `time_cycles`, tiga `op_settings`, dan 21 sensor.

2.3 Konsep RUL dan File Data




Figure 5: Hubungan antara file train, test, dan RUL — data *test* dipotong di siklus t^* ; RUL_FD001.txt berisi siklus tersisa setelah t^*

2.4 Struktur HDF5

Seluruh data disimpan dalam `cmapss_FD001.h5` menggunakan satu skrip `build_cmapss_complete.py` yang membaca langsung dari file `.txt` NASA tanpa file perantara.




Figure 6: Struktur HDF5 lengkap `cmapss_FD001.h5` di HDFView

3 Pembersihan Data

3.1 Metode

Pembersihan data dilakukan dengan menganalisis korelasi setiap sensor terhadap output (RUL). Sensor yang tidak membawa informasi degradasi dieliminasi menggunakan lima metode statistik:

1. **Standar Deviasi** — sensor konstan ($\text{std} = 0$) tidak bervariasi
2. **Koefisien Variasi (CV)** — $\text{CV} = \sigma/|\mu|$; nilai sangat kecil menunjukkan variasi tidak signifikan
3. **Korelasi Pearson vs RUL** — hubungan linear sensor terhadap output
4. **Korelasi Spearman vs RUL** — hubungan monoton sensor terhadap output
5. **Mutual Information vs RUL** — hubungan non-linear sensor terhadap output

3.2 Hasil Analisis FD001

Table 1: Statistik sensor FD001 terhadap output RUL — sensor dengan $\text{std} = 0$ ditandai (†)

Sensor	Mean	Std	CV	Pearson	Spearman	MI	Hapus
T2†	518.67	0.000	0.000	NaN	NaN	0.000	✓
T24	642.68	0.500	0.001	−0.607	−0.629	0.342	
T30	1590.5	6.131	0.004	−0.585	−0.606	0.306	
T50	1408.9	9.001	0.006	−0.679	−0.702	0.467	
P2†	14.62	0.000	0.000	NaN	NaN	0.006	✓
P15	21.61	0.001	0.000	−0.128	−0.128	0.006	✓
P30	553.37	0.885	0.002	+0.657	+0.679	0.425	
Nf	2388.1	0.071	0.000	−0.564	−0.574	0.258	
Nc	9065.2	22.08	0.002	−0.390	−0.322	0.222	
epr†	1.30	0.000	0.000	NaN	NaN	0.000	✓
Ps30	47.54	0.267	0.006	−0.696	−0.718	0.507	
phi	521.41	0.738	0.001	+0.672	+0.693	0.442	
NRf	2388.1	0.072	0.000	−0.563	−0.573	0.262	
NRc	8143.8	19.08	0.002	−0.307	−0.202	0.225	
BPR	8.44	0.038	0.004	−0.643	−0.666	0.390	
farB†	0.03	0.000	0.000	NaN	NaN	0.000	✓
htBleed	393.21	1.549	0.004	−0.606	−0.629	0.328	
Nf_dmd†	2388.0	0.000	0.000	NaN	NaN	0.000	✓
PCNfR_dmd†	100.00	0.000	0.000	NaN	NaN	0.000	✓
W31	38.82	0.181	0.005	+0.629	+0.653	0.367	
W32	23.29	0.108	0.005	+0.636	+0.657	0.380	

† $\text{std} = 0$: Pearson/Spearman tidak terdefinisi (NaN); tidak ada korelasi dengan RUL

Enam sensor dengan $\text{std} = 0$ dieliminasi: **T2**, **P2**, **epr**, **farB**, **Nf_dmd**, **PCNfR_dmd**. Sensor P15 juga dieliminasi karena $\text{CV} \approx 0$ dan Pearson = −0,13 (hampir tidak ada korelasi dengan RUL). Tersisa **15 sensor** aktif untuk normalisasi dan pemodelan.

4 Normalisasi

4.1 Metode Z-Score Berbasis Siklus Sehat




Figure 7: Pipeline normalisasi — parameter dihitung dari siklus sehat ($RUL_raw \geq 125$), diterapkan ke seluruh data

Normalisasi menggunakan formula *z-score*:

$$z = \frac{x - \mu_{\text{healthy}}}{\sigma_{\text{healthy}}} \quad (1)$$

di mana μ dan σ dihitung hanya dari siklus dengan $RUL_raw \geq 125$ (*healthy cycles*).

4.2 Alasan Penggunaan Siklus Sehat

Jika parameter dihitung dari seluruh siklus termasuk yang terdegradasi, nilai $z = 0$ tidak lagi merepresentasikan kondisi sehat. Dengan menggunakan siklus sehat sebagai referensi: siklus sehat menghasilkan $z \approx 0$, sedangkan siklus terdegradasi menyimpang dari 0 — penyimpangan inilah yang dipelajari model ANN.

4.3 Penerapan ke Data Test

Data *test* dinormalisasi menggunakan parameter dari data *train*:

$$z_{\text{test}} = \frac{x_{\text{test}} - \mu_{\text{train, healthy}}}{\sigma_{\text{train, healthy}}} \quad (2)$$

Menggunakan parameter *test* sendiri merupakan *data leakage* karena distribusi data masa depan tidak diketahui saat *deployment*.

5 Seleksi Fitur

5.1 Korelasi Pearson Antar Sensor

Matriks korelasi Pearson dihitung dari `train_normalized` untuk mengidentifikasi redundansi antar sensor.

sensor	T2	T24	T30	T50	P2	P15	P30	Nf	Nc	epr	Ps30	phi	NRf	NRc	BPR	farB	htBleed	Nf_dmd	PCNR_dmd	W31	W32
T2																					
T24																					
T30																					
T50																					
P2																					
P15																					
P30																					
Nf																					
Nc																					
epr																					
Ps30																					
phi																					
NRf																					
NRc																					
BPR																					
farB																					
htBleed																					
Nf_dmd																					
PCNR_dmd																					
W31																					
W32																					

Figure 8: Matriks korelasi Pearson antar sensor (FD001) — merah = korelasi positif kuat, biru = negatif kuat

Pasangan Nf–NRf ($r = 0,83$) dan Nc–NRc ($r = 0,96$) menunjukkan redundansi tinggi — motivasi utama penggunaan PCA untuk mereduksi dimensi.

5.2 Principal Component Analysis (PCA)

5.2.1 Varians yang Dijelaskan

PCA diterapkan pada 15 sensor ternormalisasi. Tabel berikut menunjukkan varians individual per komponen:

Table 2: Varians PCA FD001 (15 sensor → 15 komponen)

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
Individual	52,4%	30,5%	2,0%	1,8%	1,7%	1,6%	1,6%	1,4%
Kumulatif	52,4%	82,9%	84,9%	86,7%	88,4%	90,1%	91,7%	93,0%

Terdapat *scree cliff* setelah PC2: PC1 = 52,4% dan PC2 = 30,5%, kemudian PC3 hanya 2,0%. PC1 dan PC2 bersama-sama menjelaskan **82,9%** varians data.

5.2.2 Pemilihan Komponen

Kriteria **Opsi B**: pertahankan komponen dengan varians individual $\geq 5\%$. Hasilnya: **2 komponen** dipertahankan (PC1 dan PC2).

5.2.3 Interpretasi Eigenvectors

Variance summary			
component	individual variance	cumulative variance	kept?
PC1	52.42%	52.42%	YES
PC2	30.52%	82.94%	YES
PC3	1.97%	84.91%	no
PC4	1.85%	86.76%	no
PC5	1.74%	88.50%	no
PC6	1.60%	90.09%	no
PC7	1.57%	91.66%	no
PC8	1.43%	93.10%	no
PC9	1.34%	94.43%	no
PC10	1.21%	95.64%	no
PC11	1.10%	96.74%	no
PC12	1.01%	97.76%	no
PC13	0.93%	98.68%	no
PC14	0.82%	99.50%	no
PC15	0.50%	100.00%	no

Figure 9: Tabel varians dan matriks *eigenvectors* FD001 di spreadsheet v6

- **PC1** (52,4%): didominasi Nf, NRf, Nc, NRc — merepresentasikan *overall engine speed state*
- **PC2** (30,5%): kontras antara sensor kecepatan dan sensor tekanan/suhu — merepresentasikan *compressor loading condition*

5.3 Pipeline Spreadsheet

Seluruh analisis juga didokumentasikan dalam spreadsheet v1–v6:

Table 3: Evolusi spreadsheet v1–v6

Versi	Sheet Baru	Isi
v3	train, test, RUL	Data raw + kolom komputasi (condition_id, dT, RUL)
v4	train_normalized	Sensor ternormalisasi
v5	test_normalized, stats, correlation, engine_summary	Normalisasi test, statistik, korelasi, ringkasan mesin
v6	pca_params, pca_train, pca_test	Parameter PCA + skor PC per siklus

Sensor	Condition	Raw values				Normalized			
		min	max	mean	std	min	max	mean	std
T2	1	518.6700	518.6700	518.6700	0.0000	0.0000	0.0000	0.0000	0.0000
T24	1	641.2100	644.5300	642.6809	0.5001	-3.1797	5.6963	0.7528	1.3369
T30	1	1571.0400	1616.9100	1595.5231	6.1311	-3.4672	6.3911	0.7155	1.3164
T50	1	1382.2500	1441.4500	1408.9338	9.0006	-3.5472	6.4955	0.6764	1.5258
P2	1	14.6200	14.6200	14.6200	0.0000	-0.9999	-0.9999	-0.9999	0.0000
P15	1	21.6000	21.6100	21.6098	0.0014	-4.9323	0.2027	0.1017	0.7132
P30	1	549.6500	556.0800	553.3677	0.8851	-6.6096	3.4823	-0.6928	1.4382
Nf	1	2387.9000	2388.5600	2388.0967	0.0710	-2.9642	9.3070	0.6921	1.3198
Nc	1	9021.7300	9244.5900	9085.2429	22.0829	-4.2214	22.2055	0.9354	2.6186
ep	1	1.3000	1.3000	1.3000	0.0000	0.0000	0.0000	0.0000	0.0000
P30	1	46.8500	48.5300	47.5412	0.2871	-2.8856	6.7325	0.6928	1.5450
ph	1	518.6900	523.3800	521.4135	0.7376	-4.4174	3.0213	-0.9364	1.4843
Nf	1	2387.8800	2388.5600	2388.0962	0.0719	-3.2845	9.2328	0.6944	1.3239
Nf	1	8099.9400	8293.7200	8143.7527	19.0762	-4.8381	19.5312	0.6717	2.3990
ep	1	8.3249	8.5648	8.4421	0.0375	-3.6037	6.2653	0.6974	1.4270
tarB	1	0.0300	0.0300	0.0300	0.0000	-0.9999	-0.9999	-0.9999	0.0000
htBleed	1	388.0000	400.0000	393.2107	1.5488	-3.8016	6.7401	0.7754	1.3606
Nf_end	1	2388.0000	2388.0000	2388.0000	0.0000	0.0000	0.0000	0.0000	0.0000
PCWR_end	1	100.0000	100.0000	100.0000	0.0000	0.0000	0.0000	0.0000	0.0000
W31	1	35.1400	39.4300	36.8163	0.1807	-6.0468	3.9071	-0.6259	1.5947
W32	1	22.8942	23.6184	23.2897	0.1083	-5.8800	3.3745	-0.6259	1.3833

(a) Sheet stats (v5)

unit_number	time_cycles	condition_id	PC1	PC2
1	1	1	-4.526287	0.151282
2	1	2	-4.103841	-1.188677
3	1	3	-4.606003	-0.054816
4	1	4	-5.412416	-0.132677
5	1	5	-3.797527	-0.090477
6	1	6	-5.564447	0.104859
7	1	7	-4.65475	0.66526
8	1	8	-5.487274	-0.822241
9	1	9	-5.418921	-0.019763
10	1	10	-4.644905	0.474662
11	1	11	-4.810966	0.463754
12	1	12	-5.578056	0.388953
13	1	13	-2.885603	-2.011046
14	1	14	-4.401733	-0.433742
15	1	15	-4.342405	-0.974738
16	1	16	-4.342244	-0.393474
17	1	17	-3.285349	0.06857
18	1	18	-4.293987	-0.529662
19	1	19	-4.200011	-0.418518
20	1	20	-5.094859	-0.70125
21	1	21	-4.855619	-0.482773
22	1	22	-3.493167	-0.13698

(b) Sheet pca_train (v6)

Figure 10: Contoh sheet spreadsheet v5 dan v6

6 Model Artificial Neural Network

6.1 Arsitektur dan Konfigurasi

Model *Multilayer Perceptron* (MLP):

$$\text{input} \xrightarrow{W_1, \text{ReLU}} 64 \xrightarrow{W_2, \text{ReLU}} 32 \xrightarrow{W_3} 1 \quad (3)$$

Table 4: Konfigurasi pelatihan ANN

Parameter	Nilai
Arsitektur	input $\rightarrow 64 \rightarrow 32 \rightarrow 1$
Aktivasi	ReLU (tersembunyi), Linear (output)
Loss	MSE
Optimizer	Adam, lr = 10^{-3}
Epoch	500
Batch size	512
Target	RUL_capped (cap = 125 siklus)

6.2 Target: RUL Capped





Figure 11: RUL raw vs RUL capped (cap = 125) — fase sehat diratakan, model difokuskan pada fase degradasi

RUL_capped digunakan karena pada siklus awal semua mesin sehat, pembacaan sensor hampir identik meskipun RUL_raw berbeda. Cap 125 menyamakan semua siklus sehat dan memfokuskan model pada fase degradasi di mana sensor benar-benar bervariasi.

6.3 Dua Model yang Dibandingkan

- **Model PCA:** input = PC1, PC2 (2 fitur dari PCA)
- **Model NORM:** input = 15 sensor ternormalisasi langsung

6.4 Hasil



```
Terminal
C-MAPSS FD001 - ANN + Garson Pipeline
Architecture: input → 64 → 32 → 1
Epochs: 500 Batch: 512 LR: 0.001

[FD001_PCA]
Training FD001_PCA (dim=2, train=20,631, epochs=500)...
epoch 100/500 rmse=17.7636
epoch 200/500 rmse=17.7218
epoch 300/500 rmse=17.7104
epoch 400/500 rmse=17.6964
epoch 500/500 rmse=17.6865
RMSE=17.7975 MAE=12.5539 NASA=815.29
Top 5 features (Garson):
1. PC1 51.69%
2. PC2 48.31%

[FD001_NORM]
Training FD001_NORM (dim=15, train=20,631, epochs=500)...
epoch 100/500 rmse=17.7670
epoch 200/500 rmse=17.5486
epoch 300/500 rmse=17.4384
epoch 400/500 rmse=17.3664
epoch 500/500 rmse=17.2995
RMSE=18.2114 MAE=13.5197 NASA=928.52
Top 5 features (Garson):
1. P15 22.27%
2. NRc 6.70%
3. phi 6.64%
4. Nc 5.78%
5. Ps30 5.71%
```

Figure 12: Output terminal pelatihan — FD001 PCA dan NORM, 500 epoch



Figure 13: Ringkasan hasil dan perbandingan Garson

Table 5: Hasil perbandingan dua model FD001

Model	Input	Dim	RMSE	MAE	NASA Score
FD001_PCA	PC1, PC2	2	17,7975	12,5539	815,29
FD001_NORM	15 sensor	15	18,2114	13,5197	928,52

6.5 Analisis Hasil

Model PCA mengungguli NORM pada ketiga metrik. Hal ini menunjukkan bahwa kompresi PCA (82,9% varians dalam 2 komponen) efektif menghilangkan *noise* pada FD001 yang memiliki satu kondisi operasi dan satu mode kerusakan sederhana. Model NORM dengan 15 fitur memiliki lebih banyak parameter yang perlu dioptimalkan dalam jumlah epoch yang sama.

NASA Score — Model PCA menghasilkan NASA Score lebih rendah (815 vs 929), artinya lebih sedikit prediksi *late* yang berbahaya. Kurva penalti asimetris NASA Score ditunjukkan pada Gambar 14.




Figure 14: Kurva penalti NASA Score — prediksi *late* ($d > 0$) dihukum lebih berat karena membahayakan keselamatan

7 Analisis Garson

7.1 Algoritma

Algoritma Garson [2] menghitung kepentingan relatif fitur input berdasarkan bobot jaringan terlatih. Untuk arsitektur dua lapisan tersembunyi dengan matriks bobot W_1 ($64 \times n$), W_2 (32×64), W_3 (1×32):

$$q_1[i, j] = \frac{|W_1[j, i]|}{\sum_k |W_1[j, k]|} \quad q_2[j, m] = \frac{|W_2[m, j]|}{\sum_k |W_2[m, k]|} \quad (4)$$

$$r[i, m] = \sum_j q_1[i, j] \cdot q_2[j, m] \quad s[i] = \sum_m r[i, m] \cdot |W_3[m]| \quad (5)$$

$$\text{importance}[i] = \frac{s[i]}{\sum_k s[k]} \quad (6)$$

Hasilnya adalah satu skor kepentingan per fitur, total 100%.

7.2 Hasil Model PCA

Table 6: Kepentingan fitur — Model FD001_PCA

Rank	Fitur	Kepentingan (%)
1	PC1	51,69
2	PC2	48,31

Kedua komponen PCA hampir seimbang — PC1 (kecepatan mesin, 52,4% varians) dan PC2 (kontras tekanan-kecepatan, 30,5% varians) sama-sama penting untuk prediksi RUL.

7.3 Hasil Model NORM

Table 7: Kepentingan fitur — Model FD001_NORM (top 10)

Rank	Sensor	Kepentingan (%)
1	P15	22,27
2	NRc	6,70
3	phi	6,64
4	Nc	5,78
5	Ps30	5,71
6	NRf	5,69
7	W32	5,65
8	T30	5,50
9	T50	5,47
10	P30	5,30
5 sensor lainnya		25,29

7.4 Perbandingan Tiga Metode Seleksi Fitur

Table 8: Perbandingan kepentingan sensor: Pearson vs PCA vs Garson (FD001)

Sensor	Pearson	PCA Loading	Garson	Interpretasi
Ps30	−0,70	tinggi	sedang	Konsisten — penting secara linear
T50	−0,68	tinggi	sedang	Konsisten — penting secara linear
P30	+0,66	tinggi	sedang	Konsisten — penting secara linear
P15	−0,13	rendah	22,27%	Perbedaan — ANN menemukan sinyal non-linear
NRf	−0,56	sedang	rendah	Sebagian konsisten

Temuan utama: sensor **P15** memiliki korelasi Pearson rendah (−0,13) dan kontribusi PCA rendah, namun Garson menetapkan sebagai fitur terpenting (22,27%) pada model NORM. Hal ini mengindikasikan ANN mampu mengeksplorasi hubungan non-linear yang tidak terdeteksi oleh metode linear.

8 Kesimpulan

1. **Enam sensor dieliminasi** (T2, P2, epr, farB, Nf_dmd, PCNfR_dmd) karena $\text{std} = 0$ — tidak ada korelasi maupun variasi terhadap output RUL.
2. **PCA menghasilkan 2 komponen** yang menjelaskan 82,9% varians: PC1 merepresentasikan kecepatan mesin, PC2 merepresentasikan kontras tekanan-kecepatan.
3. **Model PCA mengungguli NORM** pada FD001: RMSE 17,80 vs 18,21, NASA Score 815 vs 929. Kompresi PCA efektif untuk dataset dengan 1 kondisi operasi dan 1 mode

kerusakan.

4. **Garson mengungkap sinyal non-linear**: sensor P15 — Pearson rendah, PCA rendah — terbukti paling penting menurut ANN (22,27%), menunjukkan hubungan non-linear yang tidak terdeteksi metode linear.

References

- [1] A. Saxena, K. Goebel, D. Simon, N. Eklund, “Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation,” *Proc. 1st Int. Conf. Prognostics and Health Management (PHM08)*, Denver, CO, 2008.
- [2] G.D. Garson, “Interpreting Neural Network Connection Weights,” *AI Expert*, vol. 6, no. 4, pp. 46–51, 1991.