



UNIVERSITAS INDONESIA

Fakultas Teknik – Departemen Teknik Mesin

PREDIKSI *REMAINING USEFUL LIFE*
MESIN TURBOFAN MENGGUNAKAN
ARTIFICIAL NEURAL NETWORK
PADA DATASET C-MAPSS FD001

Mata Kuliah:

Data Analitik

Dosen Pengampu:

Dr. Eng. Sholahudin, S.T., M.Sc.

Disusun Oleh:

2506565466 Luqman Alifio Arhab
2506565414 Azfa Rhazasta Abiandra
2506565401 Adamsyah Haryo Saksono
2506565433 Epsiarto Rizqi Nurwijayadi

DEPARTEMEN TEKNIK MESIN
FAKULTAS TEKNIK
UNIVERSITAS INDONESIA

2026

Contents

1	Pendahuluan	2
1.1	Latar Belakang	2
1.2	Tujuan	2
1.3	Alur Pipeline	2
2	Dataset C-MAPSS FD001	2
2.1	Deskripsi	2
2.2	Konsep RUL dan Struktur File	3
2.3	Motivasi: Mengapa RUL Sulit Diprediksi	4
2.4	Struktur HDF5	5
3	Pembersihan Data	5
3.1	Metode: Korelasi Sensor terhadap Output RUL	5
3.2	Hasil Analisis	6
4	Normalisasi	6
4.1	Metode Z-Score Berbasis Siklus Sehat	6
5	Seleksi Fitur	7
5.1	Korelasi Pearson Antar Sensor	8
5.2	Principal Component Analysis (PCA)	8
5.3	Pipeline Spreadsheet	10
6	Model <i>Artificial Neural Network</i>	10
6.1	Arsitektur dan Konfigurasi	10
6.2	Target: RUL Capped	11
6.3	NASA Score	11
6.4	Dua Model yang Dibandingkan	12
6.5	Hasil Training	12
6.6	Hasil	12
7	Analisis Garson	13
7.1	Algoritma Garson	13
7.2	Hasil Model PCA	14
7.3	Hasil Model NORM	15
7.4	Perbandingan Tiga Metode	15
8	Kesimpulan	16

1 Pendahuluan

1.1 Latar Belakang

Prediksi *Remaining Useful Life* (RUL) merupakan komponen kunci dalam sistem *Prognostics and Health Management* (PHM). Dengan mengetahui sisa umur pakai komponen sebelum kegagalan, jadwal perawatan dapat dioptimalkan sehingga mengurangi biaya *downtime* tak terencana dan risiko kegagalan mendadak.




Figure 1: Hierarki PHM — laporan ini berfokus pada lapisan *Prognostics* (prediksi RUL)

Laporan ini menggunakan sub-dataset **FD001** dari C-MAPSS NASA: satu kondisi operasi (*sea level*), satu mode kerusakan (HPC degradation), 100 mesin *train*, 100 mesin *test*.

1.2 Tujuan

1. Membersihkan data dengan analisis korelasi sensor terhadap output (RUL)
2. Menormalisasi data dengan metode *z-score* berbasis siklus sehat
3. Memilih fitur menggunakan korelasi Pearson dan PCA
4. Membangun dan membandingkan model MLP (PCA input vs sensor input)
5. Menganalisis kepentingan fitur dengan algoritma Garson

1.3 Alur Pipeline



Figure 2: Alur pipeline analitik

2 Dataset C-MAPSS FD001

2.1 Deskripsi

Dataset C-MAPSS dipublikasikan oleh NASA [1]:

<https://www.nasa.gov/intelligent-systems-division/discovery-and-systems-health/pcoe/pcoe-data-set-repository/>

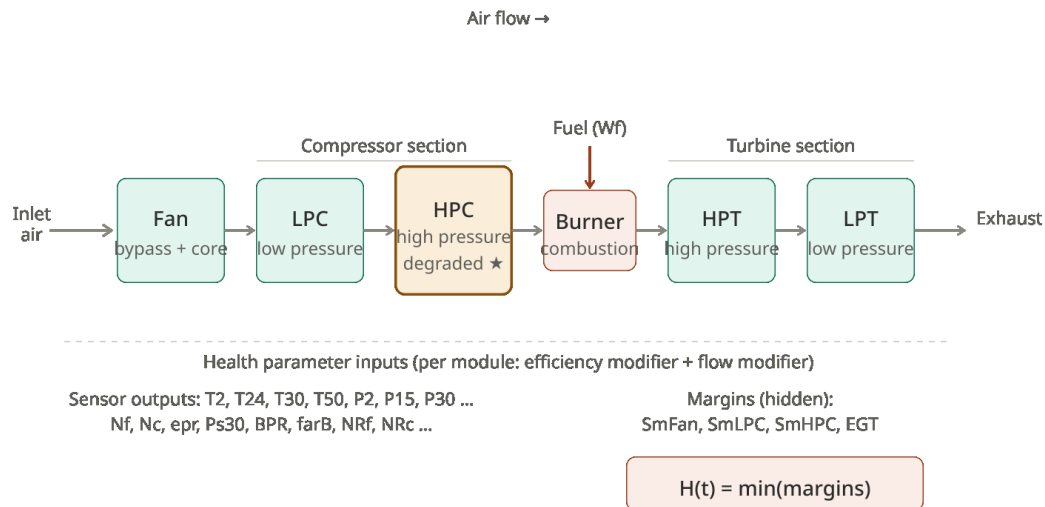


Figure 3: Skema mesin turbofan C-MAPSS — 21 sensor mengukur kondisi di sepanjang aliran udara; HPC adalah komponen yang terdegradasi pada FD001

FD001 terdiri dari 20.631 baris data *train* (100 mesin, siklus penuh hingga kegagalan) dan 13.096 baris *test* (100 mesin, dipotong sebelum kegagalan). Setiap baris memiliki 26 kolom: *unit_number*, *time_cycles*, 3 *op_settings*, dan 21 sensor.

2.2 Konsep RUL dan Struktur File




Figure 4: Hubungan antara file train, test, dan RUL — data *test* dipotong di t^* ; RUL_FD001.txt berisi kunci jawaban

2.3 Motivasi: Mengapa RUL Sulit Diprediksi




Figure 5: Trajektori degradasi sensor FD001 untuk lima mesin — sensor Ps30, T50, phi, dan P30 menunjukkan *drift* yang jelas menjelang akhir umur mesin; setiap mesin memiliki panjang hidup berbeda

Setiap mesin memiliki umur total berbeda (panjang x-axis berbeda). Sensor menunjukkan nilai yang relatif stabil di fase sehat, kemudian mulai menyimpang di fase degradasi. Model harus belajar mengenali pola penyimpangan ini untuk memprediksi berapa siklus tersisa.

2.4 Struktur HDF5




Figure 6: Struktur HDF5 lengkap `cmapss_FD001.h5` di HDFView — dibangun dari raw `.txt` NASA dalam satu skrip konsolidasi

3 Pembersihan Data

3.1 Metode: Korelasi Sensor terhadap Output RUL

Pembersihan data dilakukan dengan menganalisis hubungan setiap sensor terhadap output (RUL) menggunakan lima metode statistik:

1. **Standar Deviasi** — sensor konstan ($\text{std} = 0$) tidak bervariasi
2. **Koefisien Variasi (CV)** — $CV = \sigma/|\mu|$
3. **Korelasi Pearson vs RUL** — hubungan linear sensor terhadap output
4. **Korelasi Spearman vs RUL** — hubungan monoton terhadap output
5. **Mutual Information vs RUL** — hubungan non-linear terhadap output

3.2 Hasil Analisis

Table 1: Statistik 21 sensor FD001 terhadap output RUL — sensor dengan std = 0 (†) dieliminasi

Sensor	Mean	Std	CV	Pearson	Spearman	MI	Hapus
T2†	518.67	0.000	0.000	NaN	NaN	0.000	✓
T24	642.68	0.500	0.001	−0.607	−0.629	0.342	
T30	1590.5	6.131	0.004	−0.585	−0.606	0.306	
T50	1408.9	9.001	0.006	−0.679	−0.702	0.467	
P2†	14.62	0.000	0.000	NaN	NaN	0.006	✓
P15	21.61	0.001	0.000	−0.128	−0.128	0.006	✓
P30	553.37	0.885	0.002	+0.657	+0.679	0.425	
Nf	2388.1	0.071	0.000	−0.564	−0.574	0.258	
Nc	9065.2	22.08	0.002	−0.390	−0.322	0.222	
epr†	1.30	0.000	0.000	NaN	NaN	0.000	✓
Ps30	47.54	0.267	0.006	−0.696	−0.718	0.507	
phi	521.41	0.738	0.001	+0.672	+0.693	0.442	
NRf	2388.1	0.072	0.000	−0.563	−0.573	0.262	
NRc	8143.8	19.08	0.002	−0.307	−0.202	0.225	
BPR	8.44	0.038	0.004	−0.643	−0.666	0.390	
farB†	0.03	0.000	0.000	NaN	NaN	0.000	✓
htBleed	393.21	1.549	0.004	−0.606	−0.629	0.328	
Nf_dmd†	2388.0	0.000	0.000	NaN	NaN	0.000	✓
PCNfR_dmd†	100.00	0.000	0.000	NaN	NaN	0.000	✓
W31	38.82	0.181	0.005	+0.629	+0.653	0.367	
W32	23.29	0.108	0.005	+0.636	+0.657	0.380	

† std = 0: Pearson/Spearman tidak terdefinisi (NaN); tidak ada korelasi dengan RUL

Enam sensor dieliminasi karena std = 0: T2, P2, epr, farB, Nf_dmd, PCNfR_dmd. Sensor P15 juga dieliminasi karena Pearson = −0,13 (hampir tidak ada korelasi linear dengan RUL). Tersisa **15 sensor** aktif.

4 Normalisasi

4.1 Metode Z-Score Berbasis Siklus Sehat

$$z = \frac{x - \mu_{\text{healthy}}}{\sigma_{\text{healthy}}} \quad (1)$$

Parameter μ dan σ dihitung hanya dari siklus dengan $\text{RUL}_{\text{raw}} \geq 125$ (*healthy cycles*).




Figure 7: Perbandingan normalisasi global vs *healthy-only* untuk sensor Ps30 pada tiga mesin FD001 (Engine 1 biru 192 siklus, Engine 31 hijau ≈ 200 siklus, Engine 77 coklat 154 siklus) — garis putus-putus vertikal = awal fase degradasi per mesin (saat $RUL_raw < 125$)

Gambar 7 membandingkan dua metode normalisasi pada sensor Ps30 untuk tiga mesin. **Global z-score (kiri):** ketiga mesin mulai tersebar di nilai z berbeda — referensi nol tidak konsisten karena μ dipengaruhi siklus terdegradasi. **Healthy-only z-score (kanan):** ketiga mesin mulai di $z \approx 0$ lalu secara konsisten *drift* ke atas seiring degradasi — penyimpangan dari nol inilah sinyal yang dipelajari model.

Data *test* dinormalisasi menggunakan parameter dari *train* untuk menghindari *data leakage*.

5 Seleksi Fitur

5.1 Korelasi Pearson Antar Sensor




Figure 8: Matriks korelasi Pearson antar 15 sensor aktif FD001 — blok merah gelap pada Nc–NRc ($r = 0,96$) dan Nf–NRf ($r = 0,83$) menunjukkan redundansi tinggi yang memotivasi PCA

5.2 Principal Component Analysis (PCA)




Figure 9: Scree plot PCA FD001 — cliff tajam setelah PC2 (52,4% + 30,5% = 82,9%) menunjukkan PC3 dan seterusnya hanya mengandung noise; 2 komponen dipertahankan (varians individual $\geq 5\%$)

Table 2: Varians PCA FD001 (15 sensor → 2 komponen dipertahankan)

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8
Individual	52,4%	30,5%	2,0%	1,8%	1,7%	1,6%	1,6%	1,4%
Kumulatif	52,4%	82,9%	84,9%	86,7%	88,4%	90,1%	91,7%	93,0%




Figure 10: Scatter plot PC1 vs PC2 diwarnai berdasarkan RUL (hijau = sehat, merah = mendekati gagal) — setiap titik adalah satu siklus mesin; warna merepresentasikan RUL sebagai dimensi ketiga; titik hijau (sehat) cenderung ke kanan, merah (degraded) ke kiri

PC1 (52,4%) didominasi sensor kecepatan poros Nf, NRf, Nc, NRc — merepresentasikan *overall engine speed state*. PC2 (30,5%) merepresentasikan kontras tekanan-kecepatan.

5.3 Pipeline Spreadsheet

Figure 11(a) shows the 'stats' sheet (v5) in LibreOffice Calc. The sheet displays statistical data for various sensors across different conditions. The columns are organized as follows:

- Sensor**: Lists the sensor names (e.g., T2, T24, T30, T50, P2, P15, P30, Nf, Nc, epr, P30, phi, NfR, NfRc, sPR, farB, hBleed, Nf_end, PCHr_end, W31, W32).
- Condition**: Lists the condition IDs (e.g., 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25).
- Raw values**: Contains columns for min, max, mean, and std for each sensor.
- Normalized**: Contains columns for min, max, mean, and std for each sensor.

(a) Sheet stats (v5)

Figure 11(b) shows the 'pca_train' sheet (v6) in LibreOffice Calc. The sheet displays PCA results for various sensors across different conditions. The columns are organized as follows:

- unit_number**: Lists the unit numbers (e.g., 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25).
- time_cycles**: Lists the time cycles (e.g., 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25).
- condition_id**: Lists the condition IDs (e.g., 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20, 21, 22, 23, 24, 25).
- PC1**: Contains the first principal component values.
- PC2**: Contains the second principal component values.

(b) Sheet pca_train (v6)

Figure 11: Spreadsheet v5 dan v6 — dari statistik sensor hingga skor PC per siklus

6 Model Artificial Neural Network

6.1 Arsitektur dan Konfigurasi


Figure 12: Arsitektur MLP: input $\rightarrow 64 \rightarrow 32 \rightarrow 1$ — ReLU pada lapisan tersembunyi, output linear

Table 3: Konfigurasi pelatihan ANN

Parameter	Nilai
Arsitektur	input $\rightarrow 64 \rightarrow 32 \rightarrow 1$
Aktivasi	ReLU (tersembunyi), Linear (output)
Loss	MSE
Optimizer	Adam, lr = 10^{-3}
Epoch	500 Batch size: 512
Target	RUL_capped (cap = 125 siklus)

6.2 Target: RUL Capped




Figure 13: RUL raw vs RUL capped untuk Engine 1 (192 siklus) dan Engine 77 (154 siklus) — dua mesin ditampilkan untuk membuktikan cap bekerja konsisten terlepas dari panjang hidup mesin; fase sehat (biru) diratakan ke 125 pada kedua mesin

6.3 NASA Score




Figure 14: Kurva penalti NASA Score — prediksi *late* ($d > 0$, merah) dihukum lebih berat karena membahayakan keselamatan; prediksi *early* ($d < 0$, biru) lebih ringan

6.4 Dua Model yang Dibandingkan

- **Model PCA:** input = PC1, PC2 (2 fitur)
- **Model NORM:** input = 15 sensor ternormalisasi

6.5 Hasil Training




Figure 15: Kurva *loss* (training RMSE per epoch) — Model PCA (biru) konvergen lebih cepat karena input lebih kecil (2 vs 15 fitur); keduanya konvergen baik setelah 300 epoch

6.6 Hasil

Table 4: Perbandingan dua model FD001 (500 epoch, batch 512)

Model	Input	Dim	RMSE	MAE	NASA Score
FD001_PCA	PC1, PC2	2	17,80	12,55	815
FD001_NORM	15 sensor	15	18,21	13,52	929




Figure 16: True vs Predicted RUL untuk 100 mesin *test* — garis diagonal = prediksi sempurna; titik merah = prediksi *late* (di atas diagonal), titik biru = prediksi *early* (di bawah diagonal); pola linear karena target RUL sendiri adalah *countdown* linear




Figure 17: Distribusi error prediksi ($d = \text{pred} - \text{true}$) — distribusi *right-skewed* menunjukkan bias prediksi *late*; Model PCA memiliki distribusi lebih sempit dan bias lebih kecil

Model PCA mengungguli NORM pada ketiga metrik. Kompresi PCA (82,9% varians dalam 2 komponen) efektif membuang *noise* pada FD001 yang sederhana (1 kondisi, 1 mode kerusakan).

7 Analisis Garson

7.1 Algoritma Garson

Algoritma Garson [2] menghitung kepentingan relatif fitur input berdasarkan bobot jaringan terlatih:

$$q_1[i, j] = \frac{|W_1[j, i]|}{\sum_k |W_1[j, k]|} \quad q_2[j, m] = \frac{|W_2[m, j]|}{\sum_k |W_2[m, k]|} \quad (2)$$

$$r[i, m] = \sum_j q_1[i, j] \cdot q_2[j, m] \quad s[i] = \sum_m r[i, m] \cdot |W_3[m]| \quad (3)$$

$$\text{importance}[i] = \frac{s[i]}{\sum_k s[k]} \quad (4)$$

7.2 Hasil Model PCA




Figure 18: Kepentingan Garson Model FD001_PCA — PC1 dan PC2 hampir seimbang (51,69% vs 48,31%); kedua komponen sama-sama penting

7.3 Hasil Model NORM




Figure 19: Kepentingan Garson Model FD001_NORM — P15 mendominasi dengan 22,27% meskipun korelasi Pearson hanya $-0,13$; ANN menemukan sinyal non-linear

7.4 Perbandingan Tiga Metode




Figure 20: Perbandingan tiga metode seleksi fitur — teal = |Pearson vs RUL|, ungu = |PCA loading|, merah = Garson; area diarsir = anomali P15 yang hanya terdeteksi oleh Garson

Table 5: Perbandingan tiga metode untuk sensor pilihan (FD001)

Sensor	Pearson	PCA Loading	Garson	Interpretasi
Ps30	−0,70	tinggi	sedang	Konsisten — penting secara linear
T50	−0,68	tinggi	sedang	Konsisten — penting secara linear
P30	+0,66	tinggi	sedang	Konsisten — penting secara linear
P15	−0,13	rendah	22,27%	Anomali — sinyal non-linear terdeteksi ANN

Temuan utama: sensor P15 memiliki Pearson rendah dan PCA loading rendah, namun Garson menetapkan sebagai fitur terpenting (22,27%). ANN mengeksploitasi hubungan non-linear yang tidak terdeteksi oleh dua metode statistik linear.

8 Kesimpulan

1. **Enam sensor dieliminasi** karena $\text{std} = 0$ — tidak ada variasi maupun korelasi dengan output RUL.
2. **PCA menghasilkan 2 komponen** yang menjelaskan 82,9% varians: PC1 = kecepatan mesin, PC2 = kontras tekanan-kecepatan.
3. **Model PCA mengungguli NORM** pada FD001: RMSE 17,80 vs 18,21, NASA Score 815 vs 929.
4. **Garson mengungkap sinyal non-linear**: sensor P15 dengan Pearson −0,13 terbukti paling penting menurut ANN (22,27%).

References

- [1] A. Saxena, K. Goebel, D. Simon, N. Eklund, “Damage Propagation Modeling for Aircraft Engine Run-to-Failure Simulation,” *Proc. 1st Int. Conf. Prognostics and Health Management (PHM08)*, Denver, CO, 2008.
- [2] G.D. Garson, “Interpreting Neural Network Connection Weights,” *AI Expert*, vol. 6, no. 4, pp. 46–51, 1991.